



Ministère de l'Enseignement Supérieur et de la Recherche Scientifique
Université de Jendouba
Institut Supérieur des Langues Appliquées et d'Informatique de Béja



Réf : LA-GLSI 1/2026

Rapport de Projet de Fin d'Études

Pour l'obtention du

**DIPLÔME DE LICENCE NATIONALE EN SCIENCES DE
L'INFORMATIQUE**

Système décisionnel de prédiction du churn client par apprentissage automatique

Réalisé par :

Channoufi Ahmed

Encadré par :

Encadrant académique : M. Machta Naoufel

Encadrant professionnel : M. Jridi Ahmed

Organisme d'accueil : Tunisie Telecom

Année universitaire : 2025–2026

Dédicace

À ma famille,

Pour votre soutien et votre présence à chaque étape de ce parcours.

À mes parents,

Pour les sacrifices consentis, les nuits de veille
et la confiance que vous avez placée en moi depuis toujours.

À mes frères,

Pour votre présence, votre bonne humeur
et vos encouragements qui ont illuminé mes moments difficiles.

À mes amis,

Pour les fous rires partagés, les moments de doute surmontés ensemble
et cette amitié sincère qui a rendu ce chemin plus léger.

À mes enseignants,

Pour le savoir transmis, la patience et la passion
qui ont guidé mes pas tout au long de ma formation.

À tous ceux qui ont cru en moi,

Ce travail est le fruit de votre soutien.
Je vous le dédie avec toute ma gratitude et mon respect.

Remerciements

Avant tout, je voudrais remercier toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce travail. Leur soutien, qu'il soit technique, moral ou académique, a été précieux tout au long de cette expérience.

Je tiens particulièrement à remercier mon encadrant académique, Monsieur Naoufel Machta, dont la patience et la disponibilité m'ont été d'une grande aide. Ses conseils m'ont permis d'avancer avec clarté et confiance à chaque étape.

Un grand merci aussi à mon encadrant professionnel, Monsieur Ahmed Jridi, pour m'avoir accueilli et accompagné durant ce stage. Son encadrement m'a offert une vision concrète et enrichissante du terrain.

Enfin, je remercie les membres du jury d'avoir accepté d'évaluer ce travail. J'espère sincèrement que ce rapport saura répondre à leurs attentes.

Table des matières

Introduction générale	1
1 Cadre général du projet	2
Introduction	3
1.1 Présentation de l'organisme d'accueil	3
1.1.1 Activités de l'entreprise	3
1.1.2 Cadre du stage	3
1.2 Présentation du projet	4
1.2.1 Contexte et cadre du projet	4
1.2.2 Problématique	4
1.2.3 Solution proposée	4
1.2.4 Objectifs	4
1.3 Choix de la méthodologie	4
1.3.1 SEMMA	5
1.3.2 KDD	5
1.3.3 CRISP-DM	6
1.3.4 Comparaison des méthodologies	7
1.4 Outils et technologies utilisés	7
Conclusion	8
2 État de l'art sur la prédiction du churn	9
Introduction	10
2.1 Contexte et concepts clés	10
2.1.1 Définition du churn	10
2.1.2 Type de client churn	10
2.1.3 Stratégie et gestion des clients churn	10
2.2 Exploration de l'apprentissage automatique et du exploration de données	11
2.2.1 Définition de l'apprentissage automatique	11
2.2.2 Définition de l'exploration de données	11
2.3 Apprentissage automatique non supervisé	11
2.4 Apprentissage automatique supervisé	11
2.4.1 Modèles d'apprentissage supervisé	12

2.4.1.1	Régression logistique	12
2.4.1.2	Arbre de décision	12
2.4.1.3	Random Forest	12
2.4.1.4	Support Vector Machine linéaire	12
2.4.1.5	Gradient Boosting	12
2.4.1.6	K plus proches voisins (K-NN)	12
2.4.1.7	Naive Bayes	12
2.4.1.8	XGBoost	13
2.5	Évaluation des performances des modèles	13
2.5.1	Surapprentissage	13
2.5.2	Matrice de confusion	13
2.5.3	Exactitude	14
2.5.4	Précision	14
2.5.5	Sensibilité	14
2.5.6	Spécificité	14
2.5.7	Score F1	14
	Conclusion	14
3	Compréhension et préparation des données	15
	Introduction	16
3.1	Compréhension des données	16
3.1.1	Fichier cible	16
3.1.2	Fichier du trafic entrant	16
3.1.3	Fichier du trafic sortant	17
3.1.3.1	Fichier du trafic Internet	18
3.1.4	Fichier des recharges	19
3.1.5	Fichier des souscriptions	19
3.1.6	Période couverte par les données	20
3.1.7	Nettoyage du fichier cible	20
3.1.8	Nettoyage des données comportementales	22
3.1.8.1	Nettoyage du trafic sortant	22
3.1.8.2	Nettoyage du trafic entrant	24
3.1.8.3	Nettoyage du trafic Internet data	26
3.1.8.4	Nettoyage des données de recharge	28
3.1.8.5	Nettoyage des interactions USSD	30
3.2	Ingénierie des variables et consolidation du dataset final	32
3.2.1	Ingénierie des variables	32
3.2.2	Structure du dataset final	33
3.3	Étude de corrélation	34

3.3.1	Constitution du vecteur d'entrée	35
3.3.2	Exclusions justifiées	35
3.4	Visualisation des données	36
3.4.1	Distribution de STATUT	36
3.4.2	Répartition des types de handset par pourcentage d'utilisation	36
3.4.3	Nombre de clients par ancienneté	37
3.4.4	Distribution de la variable cible churn	38
3.4.5	Distribution des variables par rapport à la variable cible	38
3.4.5.1	Distribution de ANC_M	38
3.4.5.2	Distribution des tendances par service	39
3.4.5.3	Distribution du nombre de mois actifs par service	40
3.4.6	Distribution de la récence par service	41
	Conclusion	41
4	Modélisation, évaluation et sélection du modèle	42
	Introduction	43
4.1	Modélisation	43
4.1.1	Normalisation des données	43
4.1.2	Séparation des données d'entraînement et de test	43
4.1.3	Traitement du déséquilibre des classes	43
4.2	Entraînement et évaluation des modèles	44
4.2.1	Résultats des modèles	44
4.2.1.1	Régression logistique	44
4.2.1.2	Support Vector Machine linéaire	46
4.2.1.3	Arbre de décision	47
4.2.1.4	Random forest	48
4.2.1.5	Gradient boosting	49
4.2.1.6	Naive Bayes	50
4.2.1.7	XGBoost	51
4.3	Sélection du modèle	52
4.4	Validation du modèle sur de nouvelles données	53
4.4.1	Données utilisées pour la validation	53
4.4.1.1	Distribution de la variable churn pour février 2026	54
4.4.1.2	Résultats de validation	54
	Conclusion	55
5	Déploiement et interface web	56
	Introduction	57
5.1	Objectif du déploiement	57

5.1.1	Les diagrammes de conception	57
5.1.1.1	Diagramme de cas d'utilisation	57
5.1.1.2	Diagramme de séquence	58
5.2	Fonctionnement du tableau de bord	59
5.2.1	Indicateurs clés	59
5.2.2	Visualisations graphiques	59
5.2.3	Liste des clients à risque	60
5.3	Exportation des résultats	60
	Conclusion	61
	Conclusion générale	62

Table des figures

1.1	Logo Tunisie Telecom	3
1.2	Cycle de la méthodologie SEMMA	5
1.3	Cycle de la méthodologie KDD	6
1.4	Les six phases de la méthodologie CRISP-DM	7
2.1	Matrice de confusion	13
3.1	Répartition des valeurs manquantes	20
3.2	Valeur la plus fréquente de la variable HANDSET	20
3.3	Vérification des doublons	21
3.4	Encodage de la variable HANDSET	21
3.5	Encodage de la variable statut_next_month	21
3.6	Encodage de la variable STATUT	21
3.7	Encodage de la variable OFFRE	22
3.8	Vue globale de la cible nettoyée	22
3.9	Évaluation des valeurs manquantes (sortant)	23
3.10	Exemple de lignes sans MONTH_DT (sortant)	23
3.11	Vérification des doublons(sortant)	24
3.12	Aperçu des données sortants après nettoyage et sélection des variables (sortant)	24
3.13	Le volume final sortant	24
3.14	Évaluation des valeurs manquantes (entrant)	25
3.15	Exemple de lignes sans MONTH_DT (entrant)	25
3.16	Vérification des doublons (entrant)	26
3.17	Aperçu des données entrantes après nettoyage et sélection	26
3.18	Le volume final entrant	26
3.19	Évaluation des valeurs manquantes (data)	27
3.20	Exemple de lignes sans MONTH_DT (data)	27
3.21	Vérification des doublons (data)	27
3.22	Aperçu des données data après nettoyage et sélection	28
3.23	Volume final des données Internet	28
3.24	Évaluation des valeurs manquantes (recharges)	28
3.25	Exemple de lignes sans MONTH_DT (recharges)	29
3.26	Vérification des doublons (recharges)	29

3.27	Aperçu des données de recharge après nettoyage et sélection	29
3.28	Volume final des recharges	30
3.29	Évaluation des valeurs manquantes (USSD)	30
3.30	Exemple de lignes sans MONTH_DT (USSD)	31
3.31	Vérification des doublons — USSD	31
3.32	Aperçu des données USSD après nettoyage et sélection	31
3.33	Volume final des transactions USSD	32
3.34	Matrice de corrélation entre les variables clés et le churn	34
3.35	Distribution de status	36
3.36	Répartition des types de handset par pourcentage d'utilisation	37
3.37	Nombre de clients par ancienneté	37
3.38	Distribution de la variable cible churn	38
3.39	Distribution de ANC_M par rapport au churn	39
3.40	Distribution des tendances par service partie 1	39
3.41	Distribution des tendances par service partie 2	40
3.42	Distribution du nombre de mois actifs par service partie 1	40
3.43	Distribution du nombre de mois actifs par service partie 2	40
3.44	Distribution de la récence par service	41
4.1	Régression logistique	45
4.2	KNN	46
4.3	SVM linéaire	47
4.4	Arbre de décision	48
4.5	Random forest	49
4.6	Gradient boosting	50
4.7	Naive Bayes	51
4.8	XGBoost	52
4.9	Comparaison des performances des modèles	53
4.10	Distribution des clients churn sur les nouvelles données	54
4.11	Performance sur les nouvelles données	55
5.1	Diagramme de cas d'utilisation de l'application web	57
5.2	Diagramme de séquence de la solution déployée	58
5.3	Interface d'importation des fichiers	59
5.4	Indicateurs clés du tableau de bord	59
5.5	Visualisations graphiques	60
5.6	Liste détaillée des clients à risque	60
5.7	Export CSV des clients à risque	61

Liste des tableaux

1.1	Comparaison des méthodologies d'exploration de données	7
1.2	Environnement de développement du projet	8
3.1	Description des colonnes du fichier cible	16
3.2	Description des colonnes du fichier trafic entrant	17
3.3	Description des colonnes du fichier trafic sortant	18
3.4	Description des colonnes du fichier internet	19
3.5	Description des colonnes du fichier des recharges	19
3.6	Description des colonnes du fichier des souscriptions USSD	20
3.7	Structure finale du dataset	34
5.1	Description textuelle des cas d'utilisation	58

Introduction générale

Le secteur des télécommunications connaît une forte concurrence. Les opérateurs doivent donc faire beaucoup d'efforts pour garder leurs clients. Dans ce contexte, le churn, c'est-à-dire le départ des clients vers d'autres opérateurs, devient un problème important. Ce phénomène peut réduire les revenus de l'entreprise et influencer sa stabilité à long terme. Pour cette raison, il devient utile d'utiliser des outils capables de prévoir les clients qui risquent de partir.

Les opérateurs disposent aujourd'hui de nombreuses données sur leurs clients. Ces données peuvent concerner les appels, l'utilisation d'Internet, les recharges, les souscriptions et les différents services utilisés par les abonnés. Leur analyse permet de comprendre les habitudes des clients, de suivre l'évolution de leur comportement et de détecter certains signes de désengagement.

Cependant, le volume élevé des données et la diversité des profils clients rendent cette analyse difficile à réaliser manuellement. L'apprentissage automatique devient alors une solution intéressante, car il permet d'exploiter les données historiques pour construire un modèle capable d'estimer le risque de churn. Cette approche permet donc de transformer les données disponibles en informations utiles pour la prise de décision.

Durant ce stage, nous avons travaillé sur la prédiction du churn des clients de Tunisie Telecom par apprentissage automatique. L'objectif est d'aider l'entreprise à anticiper les départs, à mieux cibler les clients à risque et à préparer des actions de fidélisation adaptées.

Ce rapport est organisé en cinq chapitres. Le premier chapitre présente le cadre général du projet, l'organisme d'accueil, la problématique et la méthodologie adoptée. Le deuxième chapitre expose les notions théoriques liées au churn, à l'apprentissage automatique et aux métriques d'évaluation. Le troisième chapitre décrit la compréhension, le nettoyage et la préparation des données utilisées. Le quatrième chapitre présente la modélisation, l'évaluation des algorithmes et la sélection du modèle final. Enfin, le cinquième chapitre décrit le déploiement du modèle dans une application web et les principales fonctionnalités de l'interface.

Chapitre 1

Cadre général du projet

Plan

— Introduction	3
— Présentation de l'organisme d'accueil	3
— Présentation du projet	4
— Choix de la méthodologie	4
— Outils et technologies utilisés	7
— Conclusion	8

Introduction

Ce chapitre présente le contexte général du stage. Il commence par une présentation de Tunisie Télécom et du cadre du stage, puis expose la problématique du churn, la solution proposée, la méthodologie suivie et les outils utilisés.

1.1 Présentation de l'organisme d'accueil

Tunisie Télécom est une entreprise publique fondée en 1995, dont la mission est d'assurer la gestion des télécommunications à l'échelle nationale. Elle figure parmi les opérateurs majeurs d'Afrique du Nord et couvre l'ensemble du territoire tunisien à travers ses offres de téléphonie fixe, mobile et internet.

1.1.1 Activités de l'entreprise

En tant qu'opérateur national, Tunisie Télécom s'attache à fournir des services de télécommunications de qualité à l'ensemble des consommateurs tunisiens, tout en contribuant activement au développement et à la modernisation de l'infrastructure du secteur. Elle regroupe plus de 8 millions d'abonnés en téléphonie fixe et mobile, emploie plus de 8 000 agents, et s'appuie sur un réseau de 24 directions régionales ainsi que de nombreux espaces TT et points de vente répartis sur tout le territoire.

1.1.2 Cadre du stage

Tunisie Télécom s'organise autour de plusieurs directions complémentaires qui collaborent pour garantir le bon fonctionnement du réseau et la qualité du service rendu aux clients. Notre stage s'est déroulé au sein du département d'exploration de données du Centre Urbain Nord, siège social de Tunisie Télécom, une direction dédiée à l'exploitation et à l'analyse des données clients en vue d'orienter les décisions stratégiques et opérationnelles de l'entreprise. Le logo de Tunisie Telecom est présenté dans la Figure 1.1.




FIGURE 1.1 – Logo Tunisie Telecom

1.2 Présentation du projet

Cette partie présente le besoin de l'entreprise, la problématique à traiter, la solution proposée et les objectifs du projet.

1.2.1 Contexte et cadre du projet

Le secteur des télécommunications est très concurrentiel. Pour Tunisie Telecom, garder les clients existants devient donc un enjeu important. Cependant, le nombre élevé de clients et la diversité de leurs comportements rendent difficile la détection manuelle des clients à risque. L'analyse des données peut aider à mieux cibler les actions de fidélisation

1.2.2 Problématique

Dans un marché des télécommunications très concurrentiel, Tunisie Telecom perd chaque mois un nombre important de clients sans identifier les signes qui annoncent leur départ. La difficulté réside dans le volume élevé des données et la diversité des comportements clients, ce qui rend la détection manuelle des profils à risque difficile.

1.2.3 Solution proposée

Pour répondre à cette problématique, ce projet propose de développer un modèle d'apprentissage automatique capable d'analyser l'historique comportemental et transactionnel des clients afin d'identifier ceux susceptibles de résilier. Les résultats des prédictions sont ensuite intégrés dans une application web permettant à l'équipe de visualiser les profils à risque, d'analyser les résultats et d'exporter la liste des clients concernés.

1.2.4 Objectifs

L'objectif principal du projet est de mettre en place une chaîne complète allant de la préparation des données jusqu'à la prédiction du churn. Cette chaîne doit permettre d'identifier les clients les plus exposés au départ et de fournir à Tunisie Telecom un support d'aide à la décision pour orienter les actions de fidélisation.

1.3 Choix de la méthodologie

Un projet d'exploration de données doit suivre une démarche claire. Cela permet de mieux organiser les étapes, depuis la compréhension du problème jusqu'à l'évaluation des résultats. Nous présentons donc quelques méthodologies avant de justifier notre choix

1.3.1 SEMMA

SEMMA (Sample, Explore, Modify, Model and Assess) comprend les étapes suivantes :

1. **Sample** : définir les objectifs du projet et comprendre le problème métier ;
2. **Explore** : Explorer les données par des visualisations et des statistiques descriptives.
3. **Modify** : Transformer et préparer les variables pour la modélisation.
4. **Model** : Appliquer des techniques d'apprentissage automatique pour construire des modèles.
5. **Assess** : Évaluer les performances des modèles obtenus.

Le cycle SEMMA est illustré dans la Figure 1.2.




FIGURE 1.2 – Cycle de la méthodologie SEMMA

1.3.2 KDD

KDD (*Knowledge Discovery in Databases*) repose sur les étapes suivantes :

1. **Sélection** : Sélectionner les ensembles de données pertinentes.
2. **Prétraitement** : Nettoyer les données pour éliminer les erreurs.
3. **Transformation** : Transformer les données en formats appropriés pour l'exploration de données.
4. **Exploration de donnée** : Appliquer des techniques pour extraire des informations utiles.
5. **Interprétation/Évaluation** : Interpréter et évaluer les résultats obtenus.

La Figure 1.3 présente les étapes du KDD.




FIGURE 1.3 – Cycle de la méthodologie KDD

1.3.3 CRISP-DM

CRISP-DM (Cross-Industry Standard Process for Data Mining) se structure selon les étapes suivantes :

1. **Compréhension du domaine d'activité** : définir les objectifs du projet et comprendre le problème métier ;
2. **Compréhension des données** : collecter, analyser et explorer les données disponibles ;
3. **Préparation des données** : nettoyer, transformer et consolider les données avant la modélisation ;
4. **Modélisation** : entraîner plusieurs modèles prédictifs et comparer leurs performances ;
5. **Évaluation** : vérifier que le modèle obtenu répond aux objectifs fixés ;
6. **Déploiement** : intégrer le modèle dans une solution exploitable par l'utilisateur final.

Les six phases de CRISP-DM sont représentées dans la Figure 1.4.




FIGURE 1.4 – Les six phases de la méthodologie CRISP-DM

1.3.4 Comparaison des méthodologies

Le choix de la méthodologie dépend de sa capacité à couvrir tout le cycle du projet, depuis la compréhension du besoin de Tunisie Telecom jusqu'à l'intégration du modèle dans une application. Le Tableau 1.1 synthétise la comparaison entre SEMMA, KDD et CRISP-DM.

Critère	SEMMA	CRISP-DM	KDD
Flexibilité	Faible	Élevée	Modérée
Facilité d'utilisation	Modérée	Élevée	Faible
Orienté métier	Non	Oui	Non
Popularité	Modérée	Très élevée	Modérée
Nombre d'étapes	5	6	5
Adaptabilité	Faible	Très élevée	Faible

TABLE 1.1 – Comparaison des méthodologies d'exploration de données

Dans ce travail, CRISP-DM a été retenue parce qu'elle commence par la compréhension du besoin métier et se termine par une phase de déploiement. Cette logique correspond au projet réalisé : analyser le churn, préparer les fichiers clients, entraîner les modèles, comparer leurs performances puis intégrer le modèle sélectionné dans une interface web.

1.4 Outils et technologies utilisés

Cette section regroupe les principaux outils utilisés pour préparer les données, entraîner les modèles et développer l'application web. Le Tableau 1.2 précise le rôle de chaque outil dans

le projet.


Logo	Description
	Python est utilisé pour le traitement des données, la création des variables et l'entraînement des modèles avec Pandas, NumPy, Scikit-learn, Matplotlib.
	Jupyter Notebook est utilisé pour organiser les expérimentations, explorer les données, tester les modèles et présenter les résultats dans un même document.
	Anaconda facilite la gestion de l'environnement Python et des bibliothèques nécessaires au projet.
 Flask	Flask est utilisé pour développer l'application web et relier l'interface au modèle d'apprentissage automatique.
	HTML, CSS et JavaScript sont utilisés pour construire l'interface web, organiser les pages et ajouter de l'interactivité.
 Visual Studio Code	Visual Studio Code est utilisé pour écrire, organiser et modifier le code du projet.
	StarUML est utilisé pour concevoir les diagrammes UML de l'application.

TABLE 1.2 – Environnement de développement du projet

Conclusion

Ce premier chapitre a posé le cadre du stage en présentant Tunisie Telecom, la problématique et la solution proposée. La méthodologie adoptée et les outils mobilisés. Le chapitre suivant introduit les notions théoriques liées au churn, à l'apprentissage automatique et aux métriques utilisées pour évaluer les modèles.

Chapitre 2

État de l’art sur la prédiction du churn

Plan

— Introduction	10
— Contexte et concepts clés	10
— Exploration de l’apprentissage automatique et du exploration de données	11
— Apprentissage automatique non supervisé	11
— Apprentissage automatique supervisé	11
— Évaluation des performances des modèles	13
— Conclusion	14

Introduction

Ce chapitre revient sur les notions nécessaires pour comprendre la prédiction du churn. Il présente d'abord les concepts liés à la fidélisation des clients, puis les méthodes d'apprentissage automatique et d'exploration de données couramment utilisées pour traiter ce type de problème dans le secteur télécom.

2.1 Contexte et concepts clés

Cette section définit le churn et explique ses principales formes, avant d'aborder les stratégies généralement utilisées pour limiter le départ des clients.

2.1.1 Définition du churn

Le churn désigne le départ d'un client ou la fin de sa relation avec un service. Dans le contexte des télécommunications, il correspond par exemple à un abonné qui cesse d'utiliser une offre ou qui résilie son contrat. On le mesure généralement à l'aide du taux d'attrition, calculé sur une période donnée :

$$\text{Taux de churn} = \frac{\text{Nombre de clients perdus}}{\text{Nombre de clients total}}$$

2.1.2 Type de client churn

Dans les télécommunications, on distingue deux formes de churn. Le churn involontaire concerne les clients désactivés par l'opérateur, par exemple à cause d'impayés. Le churn volontaire concerne les clients qui choisissent eux-mêmes de quitter l'opérateur. Cette deuxième forme est la plus importante pour les actions de fidélisation.

2.1.3 Stratégie et gestion des clients churn

Pour réduire le churn, les entreprises peuvent améliorer le service client, proposer des offres adaptées et lancer des actions de fidélisation. L'analyse des données aide à identifier les clients fragiles et à mieux cibler ces actions.

La gestion du churn est donc un enjeu économique direct. Un client perdu représente non seulement une baisse de revenu, mais aussi un coût potentiel pour le remplacer par un nouveau client. Anticiper le départ devient ainsi plus intéressant que réagir après la résiliation.

2.2 Exploration de l'apprentissage automatique et de l'exploration de données

Avant de passer aux modèles, il est nécessaire de distinguer deux notions utilisées tout au long du travail : l'apprentissage automatique et la exploration de données.

2.2.1 Définition de l'apprentissage automatique

L'apprentissage automatique est un domaine de l'intelligence artificielle qui permet à un modèle d'apprendre à partir des données. Dans la prédiction du churn, il peut apprendre à relier certains comportements clients à un risque de départ.

2.2.2 Définition de l'exploration de données

La exploration de données consiste à explorer de grands ensembles de données afin d'en extraire des informations utiles. Dans ce projet, il permet de transformer les données clients en indicateurs utilisés pour prédire le churn.

2.3 Apprentissage automatique non supervisé

L'apprentissage non supervisé est utilisé lorsque les données ne possèdent pas de classe cible. Le modèle cherche alors des groupes ou des similarités dans les données. Cette approche peut servir à segmenter les clients.

2.4 Apprentissage automatique supervisé

L'apprentissage supervisé consiste à entraîner un modèle avec des exemples déjà étiquetés. Dans notre cas, les données indiquent si un client est classé churn ou non. Le modèle apprend à partir de ces exemples pour prédire le statut de nouveaux clients.

On distingue principalement deux familles de problèmes supervisés :

- Classification : qui est utilisée lorsque la variable cible prend un nombre fini de catégories. L'objectif est d'attribuer chaque observation à l'une des classes prédéfinies.
- Régression : qui s'applique lorsque la variable cible est continue. Elle consiste à estimer une valeur numérique à partir des variables d'entrée.

Notre problème relève de la classification, puisqu'il s'agit de prédire si un client churn ou non.

2.4.1 Modèles d'apprentissage supervisé

Les modèles présentés ci-dessous sont des algorithmes de classification pouvant être appliqués à notre problème, où il faut séparer les clients à risque des clients considérés comme stables.

2.4.1.1 Régression logistique

La régression logistique est un algorithme supervisé utilisé pour les problèmes de classification. Elle estime la probabilité qu'une observation appartienne à une classe donnée à l'aide d'une fonction logistique.

2.4.1.2 Arbre de décision

L'arbre de décision est un modèle qui prend des décisions sous forme d'une structure arborescente composée de nœuds et de branches afin de classer les données.

2.4.1.3 Random Forest

Random Forest est une méthode d'ensemble basée sur plusieurs arbres de décision construits aléatoirement. La prédiction finale est obtenue par vote majoritaire des arbres.

2.4.1.4 Support Vector Machine linéaire

Le SVM linéaire est un algorithme de classification qui cherche à trouver la meilleure frontière de séparation entre les classes afin de maximiser la marge entre les données.

2.4.1.5 Gradient Boosting

Gradient Boosting est une méthode d'ensemble basée sur plusieurs arbres de décision construits progressivement, où chaque nouvel arbre cherche à corriger les erreurs du modèle précédent afin d'améliorer les prédictions.

2.4.1.6 K plus proches voisins (K-NN)

K-Nearest Neighbors est un algorithme de classification basé sur la similarité entre les données. Il classe une nouvelle observation selon les classes des voisins les plus proches.

2.4.1.7 Naive Bayes

Naive Bayes est un algorithme de classification basé sur le théorème de Bayes. Il suppose que les variables sont indépendantes entre elles afin de calculer la probabilité qu'une observation appartienne à une classe donnée.

2.4.1.8 XGBoost

XGBoost, ou *Extreme Gradient Boosting*, est une bibliothèque optimisée de gradient boosting conçue pour être efficace, flexible et portable. Elle implémente des algorithmes d'apprentissage automatique dans le cadre du *Gradient Boosting*, en construisant plusieurs arbres de décision de manière séquentielle afin que chaque nouvel arbre corrige progressivement les erreurs des arbres précédents (XGBoost, 2026).

2.5 Évaluation des performances des modèles

Un bon modèle ne se juge pas uniquement sur son taux de réussite global. Il faut aussi savoir où il se trompe. Pour cela, plusieurs métriques sont utilisées : la matrice de confusion, l'exactitude, la précision, la sensibilité, la spécificité et le score F1.

2.5.1 Surapprentissage

Le surapprentissage (overfitting) survient lorsqu'un modèle apprend trop précisément les données d'entraînement et perd en efficacité sur de nouvelles données.

2.5.2 Matrice de confusion

La matrice de confusion croise les prédictions du modèle avec les valeurs réelles, comme illustré dans la Figure 2.1, Elle catégorise les résultats en quatre types :

1. **Vrais positifs (VP)** : nombre de clients churn correctement identifiés par le modèle.
2. **Vrais négatifs (VN)** : nombre de clients non churn correctement identifiés par le modèle.
3. **Faux positifs (FP)** : nombre de clients non churn incorrectement identifiés comme churn par le modèle.
4. **Faux négatifs (FN)** : nombre de clients churn incorrectement identifiés comme non churn par le modèle.

		Valeurs prédites	
		Non churn (0)	Churn (1)
Valeurs réelles	Non churn (0)	VN	FP
	Churn (1)	FN	VP

FIGURE 2.1 – Matrice de confusion

2.5.3 Exactitude

L'exactitude (ou Accuracy) mesure la part des prédictions correctes sur l'ensemble des prédictions. Elle est calculée selon la formule :

$$\text{Exactitude} = \frac{VP + VN}{VP + VN + FP + FN}$$

2.5.4 Précision

La précision évalue la fiabilité des alertes churn émises par le modèle. Elle est calculée selon la formule :

$$\text{Précision} = \frac{VP}{VP + FP}$$

2.5.5 Sensibilité

La sensibilité (ou recall) représente la proportion de clients churn correctement détectés par le modèle. Elle est calculée par la formule suivante :

$$\text{Sensibilité} = \frac{VP}{VP + FN}$$

2.5.6 Spécificité

La spécificité représente la proportion de clients non churn correctement classifiés par le modèle. La formule de calcul de cette métrique est la suivante :

$$\text{Spécificité} = \frac{VN}{VN + FP}$$

2.5.7 Score F1

Le score F1 est la moyenne harmonique de la précision et de la sensibilité. Il est utile lorsque ces deux mesures doivent être équilibrées. Il est calculé comme suit :

$$F1 = \frac{2 \times \text{Précision} \times \text{Sensibilité}}{\text{Précision} + \text{Sensibilité}}$$

Conclusion

Ce chapitre a présenté les fondements de l'apprentissage automatique et de l'exploration de données, ainsi que les principaux modèles de classification supervisée utilisés dans ce projet. Il a également introduit les métriques d'évaluation permettant de comparer les modèles et de sélectionner la solution la plus adaptée au problème de prédiction du churn.

Chapitre 3

Compréhension et préparation des données

Plan

— Introduction	16
— Compréhension des données	16
— Ingénierie des variables et consolidation du dataset final	32
— Étude de corrélation	34
— Visualisation des données	36
— Conclusion	42

Introduction

Ce chapitre retrace l'évolution des données brutes vers un dataset exploitable pour la modélisation. L'étude commence par la source des données et se termine par l'analyse des transformations effectuées durant le nettoyage. L'ingénierie des variables convertit les transactions en comportements permettant de détecter le désengagement du client avant son départ. Une analyse graphique valide ensuite les variables avant la modélisation.

3.1 Compréhension des données

Les données utilisées dans ce projet proviennent du système d'information de Tunisie Telecom. Elles sont organisées sous forme de fichiers CSV séparés, chacun représentant une famille d'informations : profil client, trafic d'appels, consommation Internet, opérations de recharge et transactions USSD. Cette séparation impose une étape de compréhension de chaque fichier avant leur consolidation autour de l'identifiant client.

3.1.1 Fichier cible

Ce fichier regroupe les informations de base des clients ainsi que la variable cible. Il comprend 34 000 lignes et 8 colonnes. Les champs du fichier cible sont résumés dans le Tableau 3.1.

Nom de la colonne	Description	Type	Catégorie
CODE_CONTRAT	Identifiant unique du client.	string	Qualitative
ANC_J	Ancienneté du client exprimée en jours.	int	Quantitative
ANC_M	Ancienneté du client exprimée en mois.	int	Quantitative
OFFRE	Offre commerciale associée au client .	string	Qualitative
STATUT	statut au moi courant .	string	Qualitative
HANDSET	Technologie du terminal utilisé par le client.	string	Qualitative
statut_next_month	variable cible (Target) : statut de la mois suivant.	string	Qualitative

TABLE 3.1 – Description des colonnes du fichier cible

3.1.2 Fichier du trafic entrant

Ce fichier retrace, pour chaque client, les appels et SMS reçus ainsi que leur durée selon le réseau d'origine. Il contient 352 982 lignes et 8 colonnes. Le Tableau 3.2 détaille les variables relatives au trafic entrant.

Nom de la colonne	Description	Type	Catégorie
CODE_CONTRAT	Identifiant unique du client (Clé de jointure).	string	Qualitative
MONTH_DT	Mois d'observation au format texte.	string	Qualitative
DUREE_APPEL_IN	Durée totale de tous les appels reçus.	float	Quantitative
DUREE_TT_GSM_IN	Durée des appels reçus depuis un mobile TT.	float	Quantitative
DUREE_TT_FIXE_IN	Durée des appels reçus depuis un fixe TT.	float	Quantitative
DUREE_OOREDOO_IN	Durée des appels reçus depuis Ooredoo.	float	Quantitative
DUREE_ORANGE_IN	Durée des appels reçus depuis Orange.	float	Quantitative
DUREE_OFFNET_IN	Durée totale des appels reçus hors réseau TT (Off-net).	float	Quantitative
DUREE_APPEL_INTER	Durée des appels reçus depuis l'international.	float	Quantitative
NB_SMS_IN	Nombre total de SMS reçus.	int	Quantitative
NB_SMS_TT_GSM_IN	Nombre de SMS reçus depuis un mobile TT.	int	Quantitative
NB_SMS_OOREDOO_IN	Nombre de SMS reçus depuis Ooredoo.	int	Quantitative
NB_SMS_ORANGE_IN	Nombre de SMS reçus depuis Orange.	int	Quantitative
NB_SMS_OFFNET_IN	Nombre total de SMS reçus hors réseau TT.	int	Quantitative
NB_SMS_INTER_IN	Nombre de SMS reçus depuis l'international.	int	Quantitative

TABLE 3.2 – Description des colonnes du fichier trafic entrant

3.1.3 Fichier du trafic sortant

Ce fichier retrace, pour chaque client, les appels et SMS émis, les durées par réseau de destination ainsi que les revenus générés. Il contient 330 000 lignes et 6 colonnes. Les variables du trafic sortant sont listées dans le Tableau 3.3.

Nom de la colonne	Description	Type	Catégorie
CODE_CONTRAT	Identifiant unique du client(Clé de jointure).	string	Qualitative
MONTH_DT	Mois d'observation au format texte.	string	Qualitative
revenu_cdr	Revenu total généré (Call Detail Record).	float	Quantitative
revenu_voix	Revenu généré par les appels vocaux.	float	Quantitative
revenu_sms	Revenu généré par l'envoi de SMS.	float	Quantitative
revenu_inter	Revenu généré par les appels internationaux.	float	Quantitative
revenu_roaming	Revenu généré par le service Roaming.	float	Quantitative
revenu_inter_roaming	Revenu combiné International et Roaming.	float	Quantitative
nb_APPEL_TOT	Nombre total d'appels émis.	int	Quantitative
DUREE_APPEL_TOT	Durée totale des appels émis.	float	Quantitative
Dure_offnet_TOT	Durée totale des appels émis vers les autres opérateurs.	float	Quantitative
DUREE_APPEL_OOREDOO	Durée des appels émis vers Ooredoo.	float	Quantitative
DUREE_APPEL_ORANGE	Durée des appels émis vers Orange.	float	Quantitative
DUREE_APPEL_LYCA	Durée des appels émis vers Lycamobile.	float	Quantitative
DUREE_APPEL_NESSMA	Durée des appels émis vers Nessma Mobile.	float	Quantitative
nb_sms_tot	Nombre total de SMS envoyés.	int	Quantitative

TABLE 3.3 – Description des colonnes du fichier trafic sortant

3.1.3.1 Fichier du trafic Internet

Ce fichier retrace la consommation de internet par client. 164 563 lignes et 3 colonnes. La structure du fichier Internet est donnée dans le Tableau 3.4.

Nom de la colonne	Description	Type	Catégorie
CODE_CONTRAT	Identifiant unique du client (Clé de jointure).	string	Qualitative
MONTH_DT	Mois d'observation au format texte.	string	Qualitative
VOLUME_SESSION	Volume total de données consommé (Go) durant le mois.	float	Quantitative

TABLE 3.4 – Description des colonnes du fichier internet

3.1.4 Fichier des recharges

Ce fichier comportement de rechargement du solde par client . 282 241 lignes et 15 colonnes. Les informations liées aux recharges sont synthétisées dans le Tableau 3.5.

Nom de la colonne	Description	Type	Catégorie
CODE_CONTRAT	Identifiant unique du client (Clé de jointure).	string	Qualitative
MONTH_DT	Mois d'observation au format texte.	string	Qualitative
MNT_RECH	Montant total rechargé durant le mois.	float	Quantitative
NB_RECH	Nombre total d'opérations de recharge effectuées.	int	Quantitative
MNT_RECH_SUP5	Montant cumulé des Recharges supérieures à 5 DT.	float	Quantitative
NB_RECH_SUP5	Nombre de recharges d'un montant supérieur à 5 DT.	int	Quantitative

TABLE 3.5 – Description des colonnes du fichier des recharges

3.1.5 Fichier des souscriptions

Ce fichier retrace les achats de forfaits par client. 145 793 lignes et 6 colonnes. Les variables relatives aux souscriptions USSD figurent dans le Tableau 3.6.

Nom de la colonne	Description	Type	Catégorie
CODE_CONTRAT	Identifiant unique du contrat (Clé de jointure).	string	Qualitative
MONTH_DT	Mois d'observation au format texte.	string	Qualitative
NB FORFAIT	Nombre total de forfaits souscrits (tout type confondu).	int	Quantitative
MNT FORFAIT	Montant total dépensé pour ces forfaits.	float	Quantitative
NB FORFAIT DATA	Nombre spécifique de forfaits Internet achetés.	int	Quantitative

Nom de la colonne	Description	Type	Catégorie
MNT_FORFAIT_DATA	Montant dépensé uniquement pour l'achat de forfaits Internet.	float	Quantitative

TABLE 3.6 – Description des colonnes du fichier des souscriptions USSD

3.1.6 Période couverte par les données

Les données utilisées dans ce projet couvrent la période du 1 janvier 2025 au 1 janvier 2026. Dans le fichier cible, la variable STATUT représente l'état du client pendant le mois courant, c'est-à-dire janvier 2026. La variable statut_next_month représente l'état du client au mois suivant, c'est-à-dire février 2026.

3.1.7 Nettoyage du fichier cible

1) Évaluation des valeurs manquantes

L'analyse des données a identifié deux variables incomplètes. Canal_De_Vente compte 13 823 valeurs manquantes (40,66%) et HANDSET 1 302 (3,83%). Les autres variables sont complètes et comportent 34 000 observations. la Figure 3.1 présente la répartition de ces valeurs manquantes.

```

=== VALEURS MANQUANTES ===
CODE_CONTRAT      0
ANC_J             0
ANC_M             0
Canal_De_Vente    13823
HANDSET           1302
OFFRE             0
STATUT            0
statut_next_month 0
dtype: int64

```

FIGURE 3.1 – Répartition des valeurs manquantes

2) Gestion des valeurs manquantes

Canal_De_Vente a été supprimée en raison de son taux élevé de valeurs manquantes. Pour HANDSET, les valeurs absentes ont été remplacées par le mode, approche adaptée aux variables catégorielles à faible taux d'absence. La Figure 3.2 présente la plus fréquente de HANDSET.

le plus fréquente HANDSET : 4G

FIGURE 3.2 – Valeur la plus fréquente de la variable HANDSET

3) Vérification des doublons Aucun doublon n'a été détecté dans les données. La Figure 3.3 présente les résultats de cette vérification.

```
=== doublons ===  
Nombre de ligne dupliquées dans cible : 0
```

FIGURE 3.3 – Vérification des doublons

4) Encodage des données Les algorithmes de apprentissage automatique ne traitent pas directement des données textuelles. Les variables catégorielles HANDSET, statut_next_month, STATUT et OFFRE ont donc été transformées en variables numériques.

Encodage de la variable HANDSET

La variable HANDSET a été transformée par one-hot encoding, qui crée une variable binaire par catégorie (2G, 3G, 4G, 5G). La Figure 3.4 illustre cette transformation

```
Nombre de colonnes créées : 4  
['HANDSET_2G', 'HANDSET_3G', 'HANDSET_4G', 'HANDSET_5G']
```

FIGURE 3.4 – Encodage de la variable HANDSET

Encodage de la variable cible

La variable statut_next_month distingue trois catégories , A (Actif), S (Suspendu) et D (Désactivé). Dans ce projet, seul le statut D correspond au churn. Un encodage binaire a été appliqué, avec 1 pour les clients churn et 0 pour les autres. La Figure 3.5 ci-dessous présente cet encodage.

```
statut_next_month (Churn):  
Original values: ['A' 'S' 'D']  
Encoded values: [0 0 1]
```

FIGURE 3.5 – Encodage de la variable statut_next_month

Encodage de la variable STATUT

STATUT prend deux valeurs, Actif, Suspendu. Un encodage binaire a été appliqué, avec 1 pour les clients actifs et 0 pour les clients suspendus. L'encodage est présentés dans la Figure 3.6.

```
STATUT:  
Original values: ['A' 'S']  
Encoded values: [0 1]
```

FIGURE 3.6 – Encodage de la variable STATUT

Encodage de la variable OFFRE

La variable OFFRE contient un grand nombre de états. Pour la rendre utilisable par les modèles, nous avons attribué un identifiant numérique unique à chaque offre. La Figure 3.7 présente l'encodage appliqué.

```

OFFRE:
Original values: ['100% Bonus_CSS' '100% Bonus_JM' '100% Bonus_TM' '100% Bonus_TT'
'Aziza mobile 35Mil' 'Hayya' 'PRE - 1=11' 'PRE - 900 bonus' 'PRE - AHLA'
'PRE - Ahla Bonnusset' 'PRE - Binetna' 'PRE - Binetna Reinstal'
'PRE - CSS 1000% New' 'PRE - CSS Mobile 1000%' 'PRE - CSS Mobile 1500%'
'PRE - CSS Mobile 2000%' 'PRE - CSS Mobile 300%' 'PRE - CSSM 35mil/min'
'PRE - Carte Jeune' 'PRE - Classic' 'PRE - Day Pass' 'PRE - Double'
'PRE - Double Reinstal' 'PRE - Double Street' 'PRE - E.M. 1000%'
'PRE - E.M. 2000%' 'PRE - ESS 1000% New' 'PRE - ESS Mobile 1500%'
'PRE - ESS Mobile 300%' 'PRE - ESS Mobile 35mil/min'
'PRE - EST 1000% New' 'PRE - Elissa' 'PRE - Elissa 300%'
'PRE - Family Connect' 'PRE - Jawhara 1=11' 'PRE - Jawhara 300%'
'PRE - Jawhara 35Mil' 'PRE - LOL' 'PRE - Messenger' 'PRE - New Elissa'
'PRE - Offre Premium' 'PRE - Ola' 'PRE - Oulidha 1000%'
'PRE - Oulidha 2000%' 'PRE - Pass Etudiant' 'PRE - Po9' 'PRE - SIGOUNDA'
'PRE - SIM HAJJ' 'PRE - TAWWA REINSTALLED' 'PRE - TM 35mil/min'
'PRE - TT 1000%' 'PRE - TT 1500%' 'PRE - TT 2000%' 'PRE - TT 300%'
...
Encoded values: [ 0  1  2  3  4  5  6  7  8  9 10 11 12 13 14 15 16 17 18 19 20 21 22 23
24 25 26 27 28 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47
48 49 50 51 52 53 54 55 56 57 58 59 60 61 62 63 64]

```

FIGURE 3.7 – Encodage de la variable OFFRE

Une vue globale du fichier cible après nettoyage dans la Figure 3.8.

CODE_CONTRAT	ANC_J	ANC_M	OFFRE	STATUT	HANDSET_2G	HANDSET_3G	HANDSET_4G	HANDSET_5G	churn
SN_10004606	5391	177	51	0	0	0	1	0	0
SN_10006819	5393	177	21	0	1	0	0	0	0
SN_10025174	5436	178	51	0	0	0	1	0	0
SN_10030706	5431	178	62	0	1	0	0	0	0
SN_10031209	5430	178	51	0	1	0	0	0	0
SN_1003344	6022	197	51	0	0	0	1	0	0
SN_10037148	5419	177	62	0	0	0	1	0	0
SN_10038240	5416	177	51	0	1	0	0	0	0
SN_10043034	5405	177	21	0	1	0	0	0	0
SN_10051539	5404	177	63	0	0	0	0	1	0
SN_10074449	5341	175	62	0	0	0	0	1	0
SN_10075093	4402	144	51	0	1	0	0	0	0
SN_10075737	4416	145	22	0	0	0	1	0	0

FIGURE 3.8 – Vue globale de la cible nettoyée

3.1.8 Nettoyage des données comportementales

Les cinq fichiers de consommation (sortant, entrant, internet, recharges, USSD) ont été nettoyés selon une même logique, appliquée à chacun après la préparation de la base client.

3.1.8.1 Nettoyage du trafic sortant

1) Observations initiales

Le fichier brut comporte 330 000 enregistrements. 91 lignes ne contiennent aucune information temporelle (MONTH_DT manquant). La Figure 3.9 présente l'évaluation des valeurs manquantes dans le fichier sortant.


```

=== VALEURS MANQUANTES PAR COLONNE ===
CODE_CONTRAT          0
MONTH_DT              91
revenu_cdr            0
revenu_voix           0
revenu_inter          0
revenu_roaming        0
revenu_inter_roaming  0
DUREE_APPEL_TOT      0
DUREE_APPEL_OOREDOO_TOT 0
DUREE_APPEL_ORANGE_TOT 0
DUREE_APPEL_LYCA_TOT  0
DUREE_APPEL_NESSMA_TOT 0
Duree_offnet_tot     0
nb_APPEL_TOT         0
revenu_sms           0
nb_sms_tot           0
dtype: int64

```

FIGURE 3.9 – Évaluation des valeurs manquantes (sortant)

2) Traitements effectués

Suppression des lignes sans MONTH_DT

Les 91 lignes sans MONTH_DT ont été supprimées. Pour chacune d’elles, toutes les colonnes d’activité étaient à zéro, ce qui les rend inutilisables. Un exemple de ces lignes est affiché la Figure 3.10.

	CODE_CONTRAT	MONTH_DT	revenu_cdr	revenu_voix	revenu_inter	\
1426	SN_12414706	NaN	0.0	0.0	0.0	
1973	SN_1303432	NaN	0.0	0.0	0.0	
12261	SN_18700657	NaN	0.0	0.0	0.0	
14981	SN_19378878	NaN	0.0	0.0	0.0	
32371	SN_2495777	NaN	0.0	0.0	0.0	

	revenu_roaming	revenu_inter_roaming	DUREE_APPEL_TOT	\
1426	0.0	0.0	0.0	
1973	0.0	0.0	0.0	
12261	0.0	0.0	0.0	
14981	0.0	0.0	0.0	
32371	0.0	0.0	0.0	

	DUREE_APPEL_OOREDOO_TOT	DUREE_APPEL_ORANGE_TOT	DUREE_APPEL_LYCA_TOT
1426	0.0	0.0	0.0
1973	0.0	0.0	0.0
12261	0.0	0.0	0.0
14981	0.0	0.0	0.0
32371	0.0	0.0	0.0

	DUREE_APPEL_NESSMA_TOT	Duree_offnet_tot	nb_APPEL_TOT	revenu_sms	\
1426	0.0	0.0	0	0.0	
1973	0.0	0.0	0	0.0	
12261	0.0	0.0	0	0.0	
...					
14981	0				
32371	0				

FIGURE 3.10 – Exemple de lignes sans MONTH_DT (sortant)

Suppression des doublons

Aucun doublon n’a été identifié. La Figure 3.11 présente le résultat de cette vérification.

```
les valeurs dupliquées Sortant
0
```

FIGURE 3.11 – Vérification des doublons(sortant)

Formatage des dates

La variable MONTH_DT a été convertie en type date.

Filtrage de l'activité

Les lignes sans aucun appel (nb_APPEL_TOT = 0) ont été exclues pour se concentrer sur les clients réellement actifs.

Sélection des indicateurs

Les variables retenues sont nb_APPEL_TOT (fréquence), DUREE_APPEL_TOT(usage appel), revenu_cdr (revenu global) et nb_sms_tot (usage sms). Un aperçu des données après nettoyage est présenté dans la Figure 3.12.

	CODE_CONTRAT	DUREE_APPEL_TOT	nb_APPEL_TOT	nb_sms_tot	revenu_cdr	DATE_PROPRE
0	SN_10004606	416.18	287	1	0.30	2025-01-01
1	SN_10004606	171.10	188	3	1.52	2025-02-01
2	SN_10004606	418.01	327	5	1.46	2025-03-01
3	SN_10004606	283.85	229	6	2.49	2025-04-01
4	SN_10004606	79.24	100	4	0.10	2025-05-01

FIGURE 3.12 – Aperçu des données sortants après nettoyage et sélection des variables (sortant)

3) Résultat du nettoyage Le fichier final compte 326 216 lignes. La Figure 3.13 indique le volume final du fichier sortant après nettoyage.

```
--- APRÈS LE NETTOYAGE ---
Taille (Shape): (326216, 6)
```

FIGURE 3.13 – Le volume final sortant

3.1.8.2 Nettoyage du trafic entrant

1) Observations initiales

Le fichier brut contient 352 982 enregistrements. Seules 60 lignes n'avaient pas de date renseignée (MONTH_DT manquant). La Figure 3.14 présente l'évaluation des valeurs manquantes dans le fichier entrant.

```

=== VALEURS MANQUANTES PAR COLONNE ===
CODE_CONTRAT      0
MONTH_DT          60
DUREE_APPEL_IN    0
DUREE_TT_GSM_IN   0
DUREE_TT_FIXE_IN   0
DUREE_OOREDOO_IN   0
DUREE_ORANGE_IN    0
DUREE_OFFNET_IN    0
DUREE_APPEL_INTER_IN 0
NB_SMS_IN          0
NB_SMS_TT_GSM_IN   0
NB_SMS_OOREDOO_IN   0
NB_SMS_ORANGE_IN    0
NB_SMS_OFFNET_IN    0
NB_SMS_INTER_IN     0
dtype: int64

```

FIGURE 3.14 – Évaluation des valeurs manquantes (entrant)

2) Traitements effectués

Suppression des lignes sans MONTH_DT

Les 60 lignes sans MONTH_DT ont été retirées. Après vérification, ces enregistrements ne portaient aucune activité. Un exemple de lignes sans MONTH_DT dans le fichier entrant est présenté dans la Figure 3.15.

	CODE_CONTRAT	MONTH_DT	DUREE_APPEL_IN	DUREE_TT_GSM_IN	\
12294	SN_18189489	NaN	0.0	0.0	
26296	SN_22246223	NaN	0.0	0.0	
26357	SN_22292366	NaN	0.0	0.0	
36154	SN_25461805	NaN	0.0	0.0	
63546	SN_32533342	NaN	0.0	0.0	

	DUREE_TT_FIXE_IN	DUREE_OOREDOO_IN	DUREE_ORANGE_IN	DUREE_OFFNET_IN	\
12294	0.0	0.0	0.0	0.0	
26296	0.0	0.0	0.0	0.0	
26357	0.0	0.0	0.0	0.0	
36154	0.0	0.0	0.0	0.0	
63546	0.0	0.0	0.0	0.0	

	DUREE_APPEL_INTER_IN	NB_SMS_IN	NB_SMS_TT_GSM_IN	NB_SMS_OOREDOO_IN	\
12294	0.0	0	0	0	
26296	0.0	0	0	0	
26357	0.0	0	0	0	
36154	0.0	0	0	0	
63546	0.0	0	0	0	

	NB_SMS_ORANGE_IN	NB_SMS_OFFNET_IN	NB_SMS_INTER_IN
12294	0	0	0
26296	0	0	0
26357	0	0	0
36154	0	0	0
63546	0	0	0

FIGURE 3.15 – Exemple de lignes sans MONTH_DT (entrant)

Suppression des doublons

Une vérification des doublons a été effectuée . Aucun doublon n'a été détecté. La vérification des doublons dans le fichier entrant est présentée dans la Figure 3.16.

```
les valeurs dupliquées Entrant :  
0
```

FIGURE 3.16 – Vérification des doublons (entrant)

Formatage des dates

La variable MONTH_DT a été convertie en type datetime.

Filtrage de l'activité

J'ai supprimé les lignes où DUREE_APPEL_IN = 0, pour ne garder que les clients ayant réellement reçu des appels.

Sélection des variables

Trois indicateurs ont été retenus : DUREE_APPEL_IN (durée totale des appels reçus) et NB_SMS_IN (SMS reçus). La Figure 3.17 donne un aperçu des données entrantes après nettoyage et sélection.

	CODE_CONTRAT	DUREE_APPEL_IN	NB_SMS_IN	DATE_PROPRE
0	SN_10004606	283.25	144	2025-01-01
1	SN_10004606	446.52	224	2025-02-01
2	SN_10004606	300.88	186	2025-03-01
3	SN_10004606	552.88	245	2025-04-01
4	SN_10004606	318.02	33	2025-05-01

FIGURE 3.17 – Aperçu des données entrantes après nettoyage et sélection

3) Résultat

À la fin de ce traitement, 334 296 lignes restent utilisables pour la suite de l'analyse. Le volume final du fichier entrant après nettoyage est indiqué dans la Figure 3.18.

```
--- APRÈS LE NETTOYAGE ---  
Taille (Shape): (334296, 4)
```

FIGURE 3.18 – Le volume final entrant

3.1.8.3 Nettoyage du trafic Internet data

1) Observations initiales

Ce fichier contient 164 563 enregistrements. J'ai repéré quelques lignes avec des dates manquantes ou des volumes de consommation nuls. La Figure 3.19 présente l'évaluation des valeurs manquantes dans le fichier Internet.

```

=== VALEURS MANQUANTES PAR COLONNE ===
CODE_CONTRAT      0
MONTH_DT          9399
VOLUME_SESSION    0
dtype: int64

```

FIGURE 3.19 – Évaluation des valeurs manquantes (data)

2) Traitements effectués

Suppression des lignes sans MONTH_DT

Les 9 399 lignes sans MONTH_DT ont été retirées, car il était impossible de situer la consommation dans le temps. Un exemple de lignes sans MONTH_DT dans le fichier Internet est présenté dans la Figure 3.20.

	CODE_CONTRAT	MONTH_DT	VOLUME_SESSION
12	SN_10006819	NaN	0.0
25	SN_10030706	NaN	0.0
26	SN_10031209	NaN	0.0
59	SN_10075093	NaN	0.0
88	SN_10079600	NaN	0.0
112	SN_10088687	NaN	0.0
113	SN_10089385	NaN	0.0
150	SN_10117412	NaN	0.0
151	SN_10128306	NaN	0.0
152	SN_10129143	NaN	0.0

FIGURE 3.20 – Exemple de lignes sans MONTH_DT (data)

Suppression des doublons

Une vérification des doublons a été effectuée sur l'ensemble du fichier. Aucun doublon n'a été détecté. La vérification des doublons dans le fichier Internet est présentée dans la Figure 3.21.

```

les valeurs dupliquées dans Data
0

```

FIGURE 3.21 – Vérification des doublons (data)

Formatage des dates

La variable MONTH_DT a été convertie au format datetime pour s'aligner sur le reste du pipeline.

Filtrage de l'activité

J'ai supprimé les lignes où VOLUME_SESSION = 0, pour ne garder que les sessions ayant généré un trafic d'internet réel.

Sélection des variables

Trois colonnes ont été retenues : CODE_CONTRAT, VOLUME_SESSION et DATE_PROPRE. Un aperçu du fichier Internet après nettoyage et sélection est présenté dans la Figure 3.22.

	CODE_CONTRAT	VOLUME_SESSION	DATE_PROPRE
0	SN_10004606	9331.58	2025-01-01
1	SN_10004606	8738.72	2025-02-01
2	SN_10004606	7012.43	2025-03-01
3	SN_10004606	6938.86	2025-04-01
4	SN_10004606	1173.17	2025-05-01

FIGURE 3.22 – Aperçu des données data après nettoyage et sélection

3) Résultat

Après nettoyage, le fichier contient 151 921 lignes utilisables. La Figure 3.23 indique le volume final des données Internet conservées.

```
--- APRÈS LE NETTOYAGE ---
Taille (Shape): (151921, 3)
```

FIGURE 3.23 – Volume final des données Internet

3.1.8.4 Nettoyage des données de recharge

1) Observations initiales

Ce fichier brut contient 282 241 enregistrements. Seules 151 lignes n'avaient pas de date renseignée (MONTH_DT). La Figure 3.24 présente l'évaluation des valeurs manquantes dans le fichier des recharges.

```
=== VALEURS MANQUANTES PAR COLONNE ===
CODE_CONTRAT      0
MONTH_DT          151
MNT_RECH           0
NB_RECH            0
MNT_RECH_SUP5     0
NB_RECH_SUP5      0
dtype: int64
```

FIGURE 3.24 – Évaluation des valeurs manquantes (recharges)

2) Traitements effectués

Suppression des lignes sans MONTH_DT

Les 151 lignes sans MONTH_DT ont été retirées, car elles ne représentaient qu'une fraction infime du fichier et ne portaient aucune information utile. Un exemple de lignes sans MONTH_DT dans le fichier des recharges est présenté dans la Figure 3.25.

	CODE_CONTRAT	MONTH_DT	MNT_RECH	NB_RECH	MNT_RECH_SUP5	NB_RECH_SUP5
15891	SN_21090661	NaN	0.0	0	0.0	0
18940	SN_22216996	NaN	0.0	0	0.0	0
35937	SN_28614054	NaN	0.0	0	0.0	0
42328	SN_3109820	NaN	0.0	0	0.0	0
48367	SN_33216671	NaN	0.0	0	0.0	0
50983	SN_34368910	NaN	0.0	0	0.0	0
79324	SN_44018051	NaN	0.0	0	0.0	0
81533	SN_4438634	NaN	0.0	0	0.0	0
94439	SN_46939110	NaN	0.0	0	0.0	0
104122	SN_49560964	NaN	0.0	0	0.0	0

FIGURE 3.25 – Exemple de lignes sans MONTH_DT (recharges)

Suppression des doublons

Une vérification des doublons a été effectuée sur l'ensemble du fichier. Aucun doublon n'a été détecté, le fichier ne contenant que des enregistrements uniques. La vérification des doublons dans le fichier des recharges est présentée dans la Figure 3.26.

les valeurs dupliquées dans Recharge
0

FIGURE 3.26 – Vérification des doublons (recharges)

Formatage des dates

La variable MONTH_DT a été convertie en datetime pour permettre le calcul de la fréquence mensuelle des recharges.

Filtrage de l'activité

J'ai conservé uniquement les lignes avec un montant strictement positif ($MNT_RECH > 0$), pour ne modéliser que les clients actifs financièrement.

Sélection des variables

Cinq colonnes ont été retenues : DATE PROPRE, MNT RECH, NB RECH, MNT RECH SUP5 et NB RECH SUP5. La Figure 3.27 donne un aperçu des données de recharge après nettoyage et sélection.

	CODE_CONTRAT	MNT_RECH	NB_RECH	MNT_RECH_SUP5	NB_RECH_SUP5	DATE_PROPRE
0	SN_10004606	20.0	8	15.0	3	2025-01-01
1	SN_10004606	16.0	8	10.0	2	2025-02-01
2	SN_10004606	28.0	8	25.0	5	2025-03-01
3	SN_10004606	20.0	12	10.0	2	2025-04-01
4	SN_10004606	5.0	1	5.0	1	2025-05-01

FIGURE 3.27 – Aperçu des données de recharge après nettoyage et sélection

3) Résultat

Après nettoyage, le fichier contient 282 090 lignes utilisables. Le volume final des données de recharge est indiqué dans la Figure 3.28.

```
--- APRÈS LE NETTOYAGE ---  
Taille (Shape): (282090, 6)
```

FIGURE 3.28 – Volume final des recharges

3.1.8.5 Nettoyage des interactions USSD

1) Observations initiales

Le fichier brut contient 145 793 enregistrements. Cette fois, le volume de données sans MONTH_DT est plus important : 10 269 lignes n'avaient pas de MONTH_DT renseigné. La Figure 3.29 présente l'évaluation des valeurs manquantes dans le fichier USSD.

```
=== VALEURS MANQUANTES PAR COLONNE ===  
CODE_CONTRAT          0  
MONTH_DT              10269  
MNT_FORFAIT           0  
MNT_FORFAIT_DATA      0  
NB_FORFAIT            0  
NB_FORFAIT_DATA       0  
dtype: int64
```

FIGURE 3.29 – Évaluation des valeurs manquantes (USSD)

2) Traitements effectués

Suppression des lignes sans MONTH_DT

Les 10 269 lignes sans MONTH_DT ont été retirées. Sans marqueur temporel, ces enregistrements ne peuvent pas être intégrés dans le calcul des moyennes mensuelles par client. Un exemple de lignes sans MONTH_DT dans le fichier USSD est présenté dans la Figure 3.30.

	CODE_CONTRAT	MONTH_DT	MNT_FORFAIT	MNT_FORFAIT_DATA	NB_FORFAIT	\
21	SN_10030706	NaN	0.0	0.0	0	
22	SN_10031209	NaN	0.0	0.0	0	
23	SN_1003344	NaN	0.0	0.0	0	
29	SN_10043034	NaN	0.0	0.0	0	
31	SN_10074449	NaN	0.0	0.0	0	

	NB_FORFAIT_DATA
21	0
22	0
23	0
29	0
31	0

FIGURE 3.30 – Exemple de lignes sans MONTH_DT (USSD)

Suppression des doublons

J'ensemble d'Aucun doublon n'a été détecté. La vérification des doublons dans le fichier USSD est présentée dans la Figure 3.31.

les valeurs dupliquées dans USSD
0

FIGURE 3.31 – Vérification des doublons — USSD

Formatage des dates

La variable MONTH_DT a été convertie en datetime pour s'aligner sur le reste du pipeline.

Filtrage de l'activité

J'ai supprimé les lignes où NB_FORFAIT = 0, pour ne garder que les mois où le client a réellement acheté un forfait via le menu USSD.

Sélection des variables

Cinq colonnes ont été retenues : DATE PROPRE, NB FORFAIT, MNT FORFAIT, NB FORFAIT DATA et MNT FORFAIT DATA. La Figure 3.32 donne un aperçu des données USSD après nettoyage et sélection.

	CODE_CONTRAT	MNT_FORFAIT	NB_FORFAIT	NB_FORFAIT_DATA	MNT_FORFAIT_DATA	DATE_PROPRE
0	SN_10004606	16.35	9	9	16.35	2025-01-01
1	SN_10004606	10.35	7	7	10.35	2025-02-01
2	SN_10004606	19.90	21	21	19.90	2025-03-01
3	SN_10004606	16.90	18	18	16.90	2025-04-01
4	SN_10004606	4.00	4	4	4.00	2025-05-01

FIGURE 3.32 – Aperçu des données USSD après nettoyage et sélection

3) Résultat

Après suppression des dates manquantes, des doublons et des lignes sans activité, le fichier final contient 123 217 lignes utilisables. Le volume final des transactions USSD conservées est indiqué dans la Figure 3.33.

```
--- APRÈS LE NETTOYAGE ---  
Taille (Shape): (123217, 6)
```

FIGURE 3.33 – Volume final des transactions USSD

3.2 Ingénierie des variables et consolidation du dataset final

L'ingénierie des variables transforme les observations mensuelles en indicateurs synthétiques plus faciles à exploiter par les modèles de classification.

3.2.1 Ingénierie des variables

Pour chaque flux, la création des variables a été structurée autour de trois axes :

1) Analyse de la rupture (*tendance*)

Cet indicateur compare la valeur observée pendant le mois courant (m_0) avec le niveau moyen des deux mois précédents (m_1, m_2) :

$$T = \frac{\text{Moyenne}(m_1, m_2) - m_0}{\text{Moyenne}(m_1, m_2) + 1.0} \times 100$$

- **Valeur positive (+)** : l'activité du mois courant est inférieure à l'historique récent, ce qui peut indiquer une baisse d'engagement.
- **Valeur négative (-)** : l'activité du mois courant dépasse la moyenne récente, ce qui traduit un usage plus soutenu.

Les mois m_1 et m_2 ne sont pas conservés comme variables finales : ils servent à calculer la tendance afin de réduire la redondance dans le dataset.

2) Récence

La récence indique depuis combien de mois le client n'a pas réalisé d'activité sur un flux donné. Elle met donc en évidence les périodes d'inactivité récentes. Par exemple :

- `internet_recence = 0` si le client a utilisé internet ce mois-ci,
- `montant_recharge_recence = 7` si aucune recharge n'a été effectuée durant les sept derniers mois observés.

Une valeur élevée correspond à une absence d'usage plus longue et peut constituer un signal de risque.

3) Nombre de mois actifs

Cette variable mesure la régularité d'utilisation en comptant les mois où une activité est observée pour un flux donné. Par exemple :

- internet_nb_mois_actifs = 12 indique une utilisation chaque mois.
- sms_sortants_nb_mois_actifs = 0 signifie qu'aucun SMS sortant n'a été envoyé pendant la période observée.

Un nombre faible de mois actifs traduit une utilisation irrégulière, ce qui peut renforcer l'hypothèse d'un désengagement client.

3.2.2 Structure du dataset final

Après la création des variables, le dataset final fournit une vue unique par client pour la modélisation. Le Tableau 3.7 présente la structure retenue.

Bloc de variables	Nb	Variables générées
Données cible	9	CODE_CONTRAT, ANC_M, OFFRE, STATUT, HANDSET_2G, HANDSET_3G, HANDSET_4G, HANDSET_5G, churn
Appels sortants	4	appels_sortants_m0, nb_mois_actifs, recence, tendance
Appels entrants	4	appels_entrants_m0, nb_mois_actifs, recence, tendance
Internet (consommation)	4	internet_m0, nb_mois_actifs, recence, tendance
Recharges (montant)	4	montant_recharge_m0, nb_mois_actifs, recence, tendance
Forfaits (nombre total)	4	nb_forfaits_m0, nb_mois_actifs, recence, tendance
SMS sortants	4	sms_sortants_m0, nb_mois_actifs, recence, tendance
SMS entrants	4	sms_entrants_m0, nb_mois_actifs, recence, tendance
Revenu CDR	2	revenu_m0, tendance
Recharges supérieures à 5 unités (montant)	2	mnt_grandes_rech_m0, tendance
Recharges supérieures à 5 unités (nombre)	2	nb_grandes_rech_m0, tendance
Nombre de recharges	2	nb_recharges_m0, tendance
Forfaits data (nombre)	2	nb_forfaits_data_m0, tendance
Montant forfaits data	2	mnt_forfaits_data_m0, tendance
Montant total des forfaits	2	mnt_forfaits_m0, tendance
Durée des appels sortants	2	duree_appels_sortants_m0, tendance
Total	53	34 000 observations

Bloc de variables	Nb	Variables générées
-------------------	----	--------------------

TABLE 3.7 – Structure finale du dataset

Les valeurs manquantes ont été traitées selon leur type : 0 pour l'absence de consommation et 12 pour la récence sans activité.

3.3 Étude de corrélation

Après la création du dataset final, une étude de corrélation a été réalisée pour analyser les liens entre les variables explicatives et la variable cible churn.

	Churn Correlation
churn	1
STATUT	0.684008147
montant_recharge_recence	0.509006189
appels_sortants_recence	0.445658633
sms_sortants_recence	0.445658633
sms_sortants_nb_mois_actifs	-0.40306633
appels_sortants_nb_mois_actifs	-0.40306633
montant_recharge_nb_mois_actifs	-0.392509795
appels_sortants_tendance	0.370221606
appels_entrants_nb_mois_actifs	-0.352514679
sms_entrants_nb_mois_actifs	-0.352514679
sms_entrants_m0	-0.338575408
appels_entrants_recence	0.307340331
sms_entrants_recence	0.307340331
duree_appels_sortants_tendance	0.265059935
sms_entrants_tendance	0.234266116
nb_recharges_m0	-0.222702434
appels_sortants_m0	-0.219710682
revenu_m0	-0.219442529
ANC_M	-0.206297481
nb_recharges_tendance	0.197423289
appels_entrants_tendance	0.18735732
appels_entrants_m0	-0.184267254
duree_appels_sortants_m0	-0.181765724
montant_recharge_m0	-0.177387685
montant_recharge_tendance	0.165641389
revenu_tendance	0.150769115
internet_nb_mois_actifs	-0.14689631
nb_forfaits_nb_mois_actifs	-0.132853838
mnt_grandes_rech_m0	-0.128022157
nb_grandes_rech_m0	-0.124697118
nb_forfaits_m0	-0.121939608
sms_sortants_tendance	0.115571362
nb_forfaits_data_m0	-0.108028457
internet_m0	-0.106504242
internet_recence	0.102596894

FIGURE 3.34 – Matrice de corrélation entre les variables clés et le churn

D'après la matrice de corrélation de la Figure 3.34, la variable la plus corrélée avec la cible churn est STATUT (0,684). Si le client est suspendu, alors la probabilité d'appartenir à la classe churn est plus élevée.

Les variables de récence présentent aussi une corrélation positive. C'est le cas de appels_sortants_recence (0,509), sms_sortants_recence (0,445) et montant_recharge_recence. Plus la récence est élevée, plus le risque de churn augmente. La même pour les variables de tendance, comme appels_sortant_tendance (0,37) et sms_entrant_tendance (0,26).

À l'inverse, les variables de nombre de mois actifs affichent des corrélations négatives, notamment appels_entrant_nb_mois_actif (-0,352), internet_nb_mois_actif (-0,146) et appels_sortant_nb_mois_actif (-0,445). Moins le client est actif, plus son risque de churn est élevé. La même observation s'applique aux variables de volume d'usage (m0), par exemple appels_entrant_m0 (-0,338) et revenu_m0 (-0,219). Moins le client génère de trafic sur le mois courant, plus son risque de churn est élevé.

Enfin, ce résultat confirme la pertinence de ces variables pour la modélisation.

3.3.1 Constitution du vecteur d'entrée

Le modèle final s'appuie sur 46 variables structurées autour de cinq familles :

- 15 variables de niveau courant (_m0)
- 15 variables de tendance (_tendance)
- 7 variables de récence (_recence)
- 7 variables de nombre mois actifs (_nb_mois_actifs)
- 2 variables de contexte client : ANC_M et STATUT

3.3.2 Exclusions justifiées

Certaines variables ont été volontairement écartées de l'apprentissage après l'étude de corrélation et l'analyse métier :

- HANDSET et OFFRE : ces variables présentent une faible corrélation avec la cible churn. Pour OFFRE, la corrélation est de 0,020. Pour HANDSET, les corrélations restent faibles selon les modalités : HANDSET_2G (-0,066), HANDSET_3G (0,001), HANDSET_4G (0,070) et HANDSET_5G (-0,019). Elles ne reflètent donc pas directement le comportement de consommation des clients.
- CODE_CONTRAT : il s'agit d'un identifiant unique utilisé uniquement pour reconnaître chaque client. Il n'apporte pas d'information prédictive généralisable en production.
- ANC_J : Nous travaillons uniquement avec ANC_M pour éviter la répétition.

3.4 Visualisation des données

La visualisation des données permet d'explorer graphiquement les caractéristiques des variables et de valider les transformations effectuées. Cette section présente les principales visualisations réalisées dans le cadre de l'analyse exploratoire.

3.4.1 Distribution de STATUT

La distribution de la variable STATUT est présentée dans la Figure 3.35.




FIGURE 3.35 – Distribution de status

Interprétation : La distribution de l'indicateur STATUT indique que l'ensemble de client est formé principalement des clients Actifs (A) avec 25 466 et les Suspendus (S) représentant 8 534 individus. Autrement dit, il y a une plus grande proportion d'individus actifs par rapport aux suspensions.

3.4.2 Répartition des types de handset par pourcentage d'utilisation

La Figure 3.36 détaille la répartition des types de handset.




FIGURE 3.36 – Répartition des types de handset par pourcentage d'utilisation

Interprétation : Il est évident de la figure qu'il y a 62.4% des clients qui ont 4G, qui en fait est le système dominant. Il y a 30.2% des clients qui ont le système 2G, et les systèmes 3G et 5G sont minoritaires, en occupant 3.2% et 4.2% respectivement.

3.4.3 Nombre de clients par ancienneté

La répartition des clients selon leur ancienneté est présentée dans la Figure 3.37.




FIGURE 3.37 – Nombre de clients par ancienneté

Interprétation : La figure montre que la majorité des clients ont plus de 5 ans d'ancienneté, avec 16 563 abonnés. Les clients récents sont moins nombreux. Cela indique que Tunisie Telecom possède une base clients assez ancienne.

3.4.4 Distribution de la variable cible churn

La distribution comporte 84% de clients non churn contre 15,4% de churn. Ce déséquilibre peut fausser les résultats du modèle, qui risque d'ignorer la classe churn. Ce problème sera traité lors de la modélisation. La Figure 3.38 présente la distribution de la variable cible churn.




FIGURE 3.38 – Distribution de la variable cible churn

3.4.5 Distribution des variables par rapport à la variable cible

Cette section analyse la distribution des principales variables et leur relation avec la variable cible churn.

3.4.5.1 Distribution de ANC_M

La Figure 3.39 compare la distribution de l'ancienneté mensuelle avec la variable de churn.




FIGURE 3.39 – Distribution de ANC_M par rapport au churn

Interprétation : D’après les figures, les clients ayant une faible ancienneté présentent une probabilité plus élevée de résiliation. Les clients churn ont une densité plus élevée dans les valeurs basses d’ancienneté.

3.4.5.2 Distribution des tendances par service

La distribution des tendances par service est présentée dans la Figure 3.40 et la Figure 3.41




FIGURE 3.40 – Distribution des tendances par service partie 1




FIGURE 3.41 – Distribution des tendances par service partie 2

Interprétation : Les distributions montrent qu'un niveau faible ou négatif des valeurs de la tendance s'observe pour les clients non churn. Ces valeurs montrent une augmentation de la consommation. Par rapport aux clients churn, le niveau faible mais positif des valeurs de la tendance indique une diminution de la consommation.

3.4.5.3 Distribution du nombre de mois actifs par service

La Figure 3.42 et La Figure 3.43 représentent du nombre de mois actifs par service.




FIGURE 3.42 – Distribution du nombre de mois actifs par service partie 1




FIGURE 3.43 – Distribution du nombre de mois actifs par service partie 2

Interprétation : La distribution montre que, quel que soit le service, les clients non churn présentent toujours un nombre de mois actifs plus élevé que les clients churn.

3.4.6 Distribution de la récence par service

la Figure 3.44 représente la distribution de la récence d'activité par service.




FIGURE 3.44 – Distribution de la récence par service

Interprétation : La distribution montre que les clients non churn ont utilisé les services plus récemment que les clients churn. Les clients churn présentent une récence élevée sur tous les services, ce qui traduit un désengagement progressif avant le départ.

Conclusion

Dans cette partie, nous avons nettoyé les données et traité les valeurs manquantes. L'exploration des données a ensuite permis de mieux comprendre les variables, leurs distributions et leurs liens avec le churn. Ces traitements préparent la phase de modélisation.

Chapitre 4

Modélisation, évaluation et sélection du modèle

Plan

— Introduction	44
— Modélisation	44
— Entraînement et évaluation des modèles	45
— Sélection du modèle	54
— Validation du modèle sur de nouvelles données	55
— Conclusion	56

Introduction

Ce chapitre couvre la modélisation, l'évaluation et la sélection du modèle de prédiction du churn. À partir des données nettoyées et des variables identifiées, plusieurs modèles sont entraînés et comparés pour retenir le plus adapté.

4.1 Modélisation

Dans cette section, on met en place le pipeline de modélisation. La normalisation des données, la séparation des données d'entraînement et de test, ainsi que le traitement du déséquilibre des classes.

4.1.1 Normalisation des données

Certaines variables du dataset possèdent des valeurs assez élevées, alors que d'autres présentent des valeurs beaucoup plus faibles. En effet, cela risque de produire un déséquilibre lors de l'apprentissage. De cette façon, afin d'éviter cette problématique, la normalisation a été réalisé avec le Min-Max Scaling, qui normalise toutes les valeurs dans l'intervalle [0,1].

La transformation Min-Max est calculée comme suit :

$$X_{scaled} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

4.1.2 Séparation des données d'entraînement et de test

Données ont été séparées en deux groupes, X et Y. Le groupe X contient les prédictions variables alors que le groupe Y contient une seule variable cible. On a utilisé `Train_test_split()` pour diviser les données au hasard.

- 80% des données à l'entraînement ;
- 20% des données aux tests.

Le modèle est formé à partir de grandes quantités de données alors que la deuxième partie sert à évaluer la performance du modèle sur des données qu'il n'a jamais vu, ce qui nous donne une mesure objective de la qualité de modèle. La séparation finale obtenue :

- Entraînement : 23 009 clients non churn (0), 4 190 clients churn (1).
- Test : 5 752 clients non churn (0), 1 048 clients churn (1).

4.1.3 Traitement du déséquilibre des classes

Comme la variable cible a montré un déséquilibre par rapport aux deux catégories churn et non churn, SMOTE (Synthetic Minority Over-sampling Technique) a été utilisé. C'est une

technique de sur-échantillonnage qui permet de créer de nouvelles observations de la classe minoritaire à partir de ses plus proches voisins. L'intention de cette approche est de modifier la composante d'entraînement pour qu'elle soit plus facilement déduite dans le but de maximiser la capacité des modèles de prédire correctement les valeurs de la variable churn. Comme l'entraînement initial montrait un déséquilibre 23 009 clients non churn (0), 4 190 clients churn (1) avant de faire appel à SMOTE. Cependant, avec SMOTE, on a réussi à rééquilibrer complètement ces deux classes de la composition initiale de sorte qu'elles sont maintenant même taille 23 009 clients non churn (0), 23 009 clients churn (1). Il convient de noter que SMOTE est appliqué exclusivement sur notre composante d'entraînement.

4.2 Entraînement et évaluation des modèles

Après l'étape de préparation et de rééquilibrage des données, plusieurs modèles de classification sont entraînés puis évalués. Nous cherchons surtout un modèle capable de détecter les clients churn tout en conservant une performance globale acceptable.

4.2.1 Résultats des modèles

Cette partie présente les résultats de la classification effectuée via différents algorithmes la régression logistique, naïve Bayes, arbre de décision, random forest, KNN, SVM linéaire, gradient Boosting, et XGBoost.

La comparaison de performance se fera en utilisant les différentes métriques qui ont été citées au chapitre théorique dont l'exactitude, la sensibilités, la précision, le score F1, la spécificité ainsi que la matrice de confusion si besoin. Cette comparaison permettra de mettre en évidence les modèles les plus performants pour notre problème de churn prédiction.

4.2.1.1 Régression logistique

La Figure 4.1 détaille les résultats de la régression logistique.

```

===== Logistic Regression =====
              precision    recall  f1-score   support

     0       0.99      0.90      0.94      5752
     1       0.63      0.95      0.76      1048

 accuracy          0.91      6800
 macro avg       0.81      0.93      0.85      6800
 weighted avg    0.94      0.91      0.91      6800

```




FIGURE 4.1 – Régression logistique

Performance : Le modèle de régression logistique atteint une exactitude de 91%. Pour la classe churn, il obtient une précision de 63%, une sensibilité de 95%, une spécificité de 90% et un score F1 de 76%. La matrice de confusion présente les résultats suivants :

- Vrais Positifs : 1000 clients churn correctement détectés.
- Faux Négatifs : 48 clients churn non détectés.
- Faux Positifs : 584 clients non churn signalés comme churn (fausses alarmes).
- Vrais Négatifs : 5 168 clients non churn correctement classés.

Globalement, ce modèle détecte bien les clients churn réels avec une sensibilité élevée, mais sa précision reste faible, ce qui signifie qu’il classe trop de clients non churn comme churn.

===== KNN =====					
	precision	recall	f1-score	support	
0	0.99	0.91	0.95	5752	
1	0.66	0.95	0.77	1048	
accuracy			0.92	6800	
macro avg	0.82	0.93	0.86	6800	
weighted avg	0.94	0.92	0.92	6800	




FIGURE 4.2 – KNN

Performance : Le modèle KNN atteint une exactitude de 92%. Pour la classe churn, il obtient une précision de 56%, une sensibilité de 95%, une spécificité de 91% et un score F1 de 77%. La matrice de confusion présente les résultats suivants :

- Vrais Positifs : 992 clients churn correctement détectés.
- Faux Négatifs : 56 clients churn non détectés.
- Faux Positifs : 521 clients non churn signalés comme churn (fausses alarmes).
- Vrais Négatifs : 5 231 clients non churn correctement classés.

Le modèle repère la majorité des clients churn, mais manque de précision et génère trop de fausses alarmes.

4.2.1.2 Support Vector Machine linéaire

La Figure 4.3 présente les résultats obtenus par le modèle SVM linéaire.


```

===== SVM (Lineaire) =====
              precision    recall  f1-score   support

      0       0.99        0.89        0.94        5752
      1       0.62        0.95        0.75        1048

 accuracy          0.90          6800
 macro avg         0.81          0.92          0.85          6800
 weighted avg      0.93          0.90          0.91          6800

```




FIGURE 4.3 – SVM linéaire

Performance : Le SVM linéaire atteint une exactitude de 90%. Pour la classe churn, il obtient une précision de 62%, une sensibilité de 95%, une spécificité de 89% et un score F1 de 75%. La matrice de confusion présente les résultats suivants :

- Vrais Positifs : 998 clients churn correctement détectés.
- Faux Négatifs : 50 clients churn non détectés.
- Faux Positifs : 610 clients non churn signalés comme churn (fausses alarmes).
- Vrais Négatifs : 5 142 clients non churn correctement classés.

Malgré une bonne détection des clients churn, le modèle peine à distinguer les vrais clients churn des clients non churn, ce qui se reflète dans une précision limitée.

4.2.1.3 Arbre de décision

La Figure 4.4 présente les résultats obtenus par l'arbre de décision.

===== Decision Tree =====				
	precision	recall	f1-score	support
0	0.99	0.96	0.97	5752
1	0.81	0.94	0.87	1048
accuracy			0.96	6800
macro avg	0.90	0.95	0.92	6800
weighted avg	0.96	0.96	0.96	6800




FIGURE 4.4 – Arbre de décision

Performance : L'arbre de décision atteint une exactitude de 96%. Pour la classe churn, il obtient une précision de 81%, une sensibilité de 94%, une spécificité de 96% et un score F1 de 87%. La matrice de confusion présente les résultats suivants :

- Vrais Positifs : 981 clients churn correctement détectés.
- Faux Négatifs : 67 clients churn non détectés.
- Faux Positifs : 237 clients non churn signalés à tort (fausses alarmes).
- Vrais Négatifs : 5 515 clients non churn correctement classés.

Le modèle gère bien les deux classes, avec une précision élevée et peu de clients churn manqués.

4.2.1.4 Random forest

La Figure 4.5 présente les résultats obtenus par le Random Forest.

===== Random Forest =====				
	precision	recall	f1-score	support
0	0.99	0.96	0.97	5752
1	0.82	0.93	0.87	1048
accuracy			0.96	6800
macro avg	0.90	0.95	0.92	6800
weighted avg	0.96	0.96	0.96	6800




FIGURE 4.5 – Random forest

Performance : Le Random Forest atteint une exactitude de 96%. Pour la classe churn, il obtient une précision de 82%, une sensibilité de 93%, une spécificité de 96% et un score F1 de 87%. La matrice de confusion présente les résultats suivants :

- Vrais Positifs : 976 clients churn correctement détectés.
- Faux Négatifs : 72 clients churn non détectés.
- Faux Positifs : 219 clients non churn signalés comme churn (fausses alarmes).
- Vrais Négatifs : 5 533 clients non churn correctement classés.

Le modèle affiche un bon équilibre entre précision et sensibilité, avec peu de fausses alarmes et peu de clients churn manqués.

4.2.1.5 Gradient boosting

La Figure 4.6 présente les résultats obtenus par le Gradient Boosting.

```

===== Gradient Boosting =====
      precision    recall  f1-score   support

     0       0.99      0.96      0.97       5752
     1       0.82      0.93      0.87       1048

 accuracy      0.96      0.96      0.96      6800
 macro avg       0.90      0.95      0.92      6800
 weighted avg     0.96      0.96      0.96      6800

```




FIGURE 4.6 – Gradient boosting

Performance : Le Gradient Boosting atteint une exactitude de 96%. Pour la classe churn, il obtient une précision de 82%, une sensibilité de 93%, une spécificité de 96% et un score F1 de 87%. La matrice de confusion présente les résultats suivants :

- Vrais Positifs : 979 clients churn correctement détectés.
- Faux Négatifs : 69 clients churn non détectés.
- Faux Positifs : 217 clients non churn signalés à tort (fausses alarmes).
- Vrais Négatifs : 5 535 clients non churn correctement classés.

Les performances sont solides sur les deux classes, avec une précision nettement améliorée et un nombre de fausses alarmes réduit.

4.2.1.6 Naive Bayes

La Figure 4.7 présente les résultats obtenus par Naive Bayes.

```

===== Naive Bayes =====
              precision    recall  f1-score   support

     0         0.99         0.78         0.88         5752
     1         0.45         0.96         0.61         1048

 accuracy         0.81         6800
 macro avg         0.72         0.87         0.74         6800
 weighted avg         0.91         0.81         0.83         6800

```




FIGURE 4.7 – Naive Bayes

Performance : Naive Bayes affiche une exactitude de 81%. Pour la classe churn, il obtient une précision de 45%, une sensibilité de 96%, une spécificité de 78% et un score F1 de 61%. La matrice de confusion présente les résultats suivants :

- Vrais Positifs : 1 001 clients churn correctement détectés.
- Faux Négatifs : 47 clients churn non détectés.
- Faux Positifs : 1 239 clients non churn signalés à tort (fausses alarmes).
- Vrais Négatifs : 4 513 clients non churn correctement classés.

Malgré une bonne détection des clients churn, le modèle souffre d’une précision très faible et génère un nombre élevé de fausses alarmes.

4.2.1.7 XGBoost

La Figure 4.8 présente les résultats obtenus par XGBoost.

===== XGBoost =====				
	precision	recall	f1-score	support
0	0.99	0.96	0.98	5752
1	0.83	0.93	0.88	1048
accuracy			0.96	6800
macro avg	0.91	0.95	0.93	6800
weighted avg	0.96	0.96	0.96	6800




FIGURE 4.8 – XGBoost

Performance : Le modèle XGBoost atteint une exactitude de 96%. Pour la classe churn, il obtient une précision de 83%, une sensibilité de 93%, une spécificité de 96% et un score F1 de 88%. La matrice de confusion présente les résultats suivants :

- Vrais Positifs : 977 clients churn correctement détectés.
- Faux Négatifs : 71 clients churn non détectés.
- Faux Positifs : 204 clients non churn signalés comme churn (fausses alarmes).
- Vrais Négatifs : 5 548 clients non churn correctement classés.

Le modèle combine une précision élevée avec une détection fiable des clients churn, tout en limitant les fausses alarmes.

4.3 Sélection du modèle

La sélection du modèle final repose sur plusieurs critères : l'exactitude de test, le F1 Score, la précision, la sensibilité, la spécificité, le temps d'entraînement et l'écart entre l'exactitude

d'entraînement et celle de test. Cet écart permet d'estimer le risque de surapprentissage.

XGBoost obtient les meilleures performances, avec une exactitude de test de 95,96%, un F1 Score de 87,66%, une précision de 82,73% et une sensibilité de 93,23%. Son exactitude d'entraînement est de 97,41%, soit un écart de 1,46%. Cet écart reste faible, ce qui montre que le modèle généralise bien sur de nouvelles données. De plus, son temps d'entraînement est court, soit 0,93 seconde.

Gradient Boosting affiche des résultats proches, mais son temps d'entraînement est beaucoup plus long. Random Forest présente également de bonnes performances, mais l'écart entre l'entraînement et le test est plus élevé, ce qui peut indiquer un risque de surapprentissage.

Au final, XGBoost est retenu comme meilleur choix, car il offre un bon équilibre entre performance, rapidité et capacité de généralisation. La Figure 4.9 compare visuellement les performances des modèles.

Modèle	Temps d'entraînement (s)	Exactitude d'entraînement	Exactitude de test	Précision	Sensibilité	Spécificité	Score F1
Régression Logistique	0.4662	92,78%	90,71%	63,13%	95,42%	89,85%	75,99%
Naive Bayes	0.0336	87,17%	81,09%	44,69%	95,52%	78,46%	60,89%
Arbre de Décision	0.5161	96,14%	95,53%	80,54%	93,61%	95,88%	86,58%
Random Forest	9.5752	99,98%	95,72%	81,67%	93,13%	96,19%	87,03%
k-NN	0.0033	96,35%	91,51%	65,57%	94,66%	90,94%	77,47%
SVM (Linéaire)	795.3614	92,35%	90,29%	62,06%	95,23%	89,39%	75,15%
Gradient Boosting	33.8700	97,49%	95,79%	81,86%	93,42%	96,23%	87,25%
XGBoost	1.0623	97,41%	95,96%	82,73%	93,23%	96,45%	87,66%

FIGURE 4.9 – Comparaison des performances des modèles

4.4 Validation du modèle sur de nouvelles données

Après avoir choisi le modèle, ce dernier a été sauvegardé pour pouvoir être utilisé à nouveau, sans devoir refaire la phase entière d'entraînement du modèle. On peut le charger ensuite et l'appliquer à de nouvelles données pour voir s'il est capable d'obtenir un bon rendement avec ces nouvelles données.

4.4.1 Données utilisées pour la validation

Les nouvelles données utilisées pour tester le modèle concernent la même période que les données d'entraînement, mais portent sur des clients différents, non utilisés pendant l'apprentissage. Elles proviennent des mêmes fichiers mensuels et ont été préparées avec le même pipeline afin de conserver la même structure.

Les variables explicatives décrivent le comportement des clients jusqu'en janvier 2026, tandis que la variable cible churn correspond au statut du client en février 2026. Cette validation

permet donc de comparer les prédictions aux vraies valeurs et d'évaluer le modèle sur des clients non vus lors de l'entraînement.

4.4.1.1 Distribution de la variable churn pour février 2026

La distribution de la variable churn pour février 2026 est affichée dans la Figure 4.10.




FIGURE 4.10 – Distribution des clients churn sur les nouvelles données

Avant d'appliquer le modèle, nous avons analysé la distribution de la variable cible sur les 34 000 clients des nouvelles données. Pour février 2026, 14,8% sont identifiés comme churn, contre 85,2% non churn. Cette répartition reste similaire à celle utilisée lors de l'entraînement.

4.4.1.2 Résultats de validation

Les performances calculées sur les nouvelles données sont récapitulées dans la Figure 4.11.

Classification Report:				
	precision	recall	f1-score	support
0	1.00	0.96	0.98	28979
1	0.82	0.98	0.89	5021
accuracy			0.96	34000
macro avg	0.91	0.97	0.93	34000
weighted avg	0.97	0.96	0.97	34000




FIGURE 4.11 – Performance sur les nouvelles données

Le modèle XGBoost, évalué sur les 34 000 clients des nouvelles données, atteint une exactitude de 96%. Pour la classe churn, il obtient une précision de 82%, une sensibilité de 98%, une spécificité de 96% et un score F1 de 89%. La matrice de confusion confirme ces résultats :

- Vrais Positifs : 4 906 clients churn correctement détectés.
- Faux Négatifs : 115 clients churn non détectés.
- Faux Positifs : 1 095 clients non churn signalés comme churn (fausses alarmes).
- Vrais Négatifs : 27 884 clients non churn correctement classés.

Malgré le déséquilibre des classes, les résultats confirment que le modèle XGBoost généralise bien sur des données réelles et récentes.

Conclusion

Dans ce chapitre, nous avons préparé les données, entraîné plusieurs algorithmes et comparé leurs performances. XGBoost s'est avéré le modèle le plus performant. Sa validation sur les données de février confirme sa capacité à produire de bons résultats avant son exploitation dans un contexte réel.

Chapitre 5

Déploiement et interface web

Plan

— Introduction	58
— Objectif du déploiement	58
— Fonctionnement du tableau de bord	60
— Exportation des résultats	61
— Conclusion	62

Introduction

Après la validation du modèle, il était nécessaire de rendre son utilisation simple. Ce chapitre présente donc l'application web développée pour importer les fichiers mensuels, lancer la prédiction et consulter les clients à risque.

5.1 Objectif du déploiement

Le déploiement permet de transformer le modèle en outil utilisable. Plutôt que de travailler uniquement avec des notebooks ou des scripts, l'application offre une interface pour consulter les résultats. Elle transforme le modèle XGBoost en un outil d'aide à la décision.

5.1.1 Les diagrammes de conception

Cette section explique la conception de l'application grâce à deux types de diagrammes : le cas d'utilisation, qui présente une synthèse des actions possibles, et le diagramme de séquence, qui illustre l'ordre des traitements.

5.1.1.1 Diagramme de cas d'utilisation

Le diagramme de cas d'utilisation de l'application est donné dans la Figure 5.1.




FIGURE 5.1 – Diagramme de cas d'utilisation de l'application web

Description textuelle des cas d'utilisation Une description textuelle des cas d'utilisation est fournie dans le Tableau 5.1.

Cas d'utilisation	Description
Importer les fichiers mensuels	L'utilisateur importe les fichiers CSV nécessaires au traitement, notamment les données clients, sortant, entrant, internet, recharges et USSD.
Lancer la prédiction	L'utilisateur lance la prédiction pour obtenir les résultats de churn.
Consulter les indicateurs	L'utilisateur consulte les statistiques principales, comme le nombre de clients analysés et le nombre de clients à risque.
Visualiser les clients à risque	L'utilisateur consulte la liste des clients à risque de churn avec leurs probabilités, niveaux de risque et anciennetés.
Exporter les résultats CSV	L'utilisateur télécharge la liste des clients à risque de churn sous forme de fichier CSV

TABLE 5.1 – Description textuelle des cas d'utilisation

5.1.1.2 Diagramme de séquence

Diagramme de séquence explique l'ordre dans lequel ces traitements après avoir importé les fichiers. Il montre les interactions qui existent entre l'utilisateur, l'interface web, le serveur backend, pipeline de préparation et le modèle XGBoost. Les résultats s'affichent sur le tableau de bord et peuvent être exportés. La Figure 5.2 présente le diagramme de séquence du processus de prédiction.

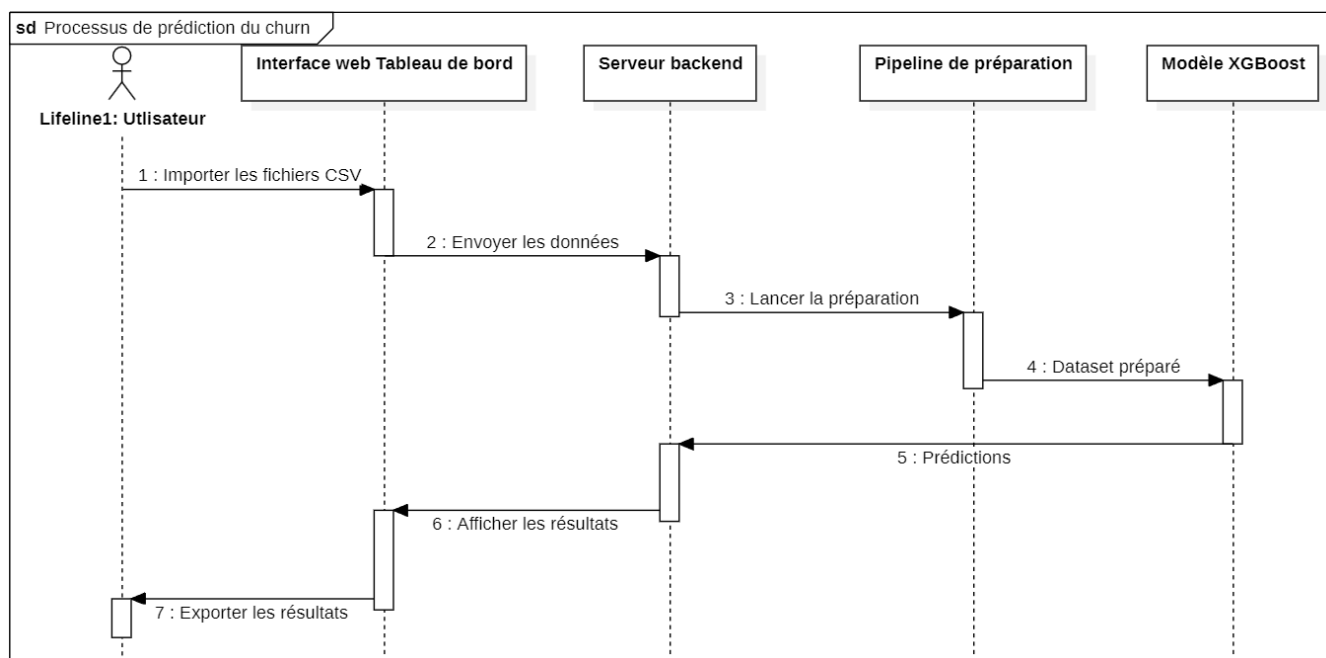


FIGURE 5.2 – Diagramme de séquence de la solution déployée

5.2 Fonctionnement du tableau de bord

Le tableau de bord a été pensé comme un espace de travail simple pour l'équipe d'exploration de données. La première étape consiste à importer les six fichiers mensuels nécessaires : client, appels sortants, appels entrants, consommation Internet, recharges et USSD.

Après l'importation, l'utilisateur lance la prédiction depuis un bouton dédié. L'application affiche un indicateur pendant l'exécution, puis met à jour automatiquement le tableau de bord lorsque les résultats sont prêts. L'écran d'importation des fichiers est montré dans la Figure 5.3.

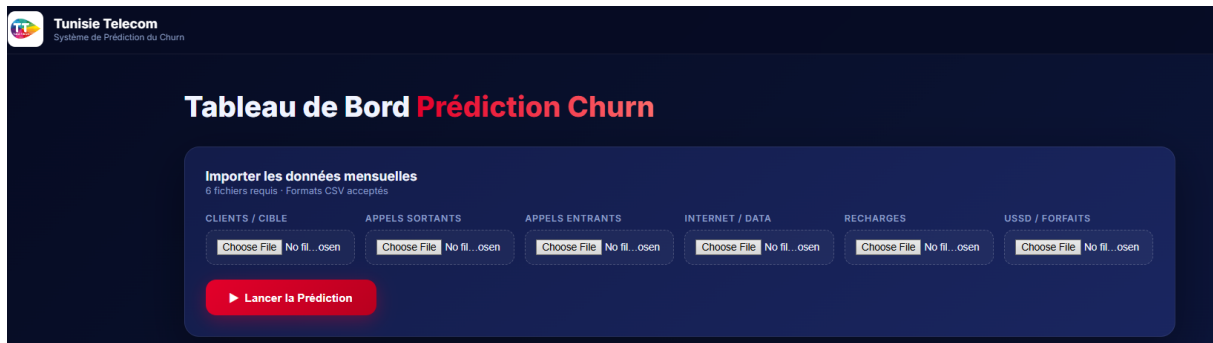


FIGURE 5.3 – Interface d'importation des fichiers

5.2.1 Indicateurs clés

Les indicateurs fournis en début de tableau de bord sont :

- Le nombre total de clients analysés ;
- Le nombre de clients ayant été classés sous catégories churn ;
- Le nombre de clients hauts risques ayant une probabilité de churn plus de 70% ;
- Le nombre de clients stables.

Ainsi, ces indicateurs offrent un aperçu instantané de l'état des clients, comme indiquée dans la Figure 5.4.




FIGURE 5.4 – Indicateurs clés du tableau de bord

5.2.2 Visualisations graphiques

Les graphiques illustrent ce travail par deux types de visualisations suivantes :

- le graphique circulaire qui indique la répartition des clients selon les trois types de risque (risque faible, risque moyen, et risque fort) ;

— l’histogramme qui indique la probabilité de churn de chaque 10% par intervalles.

Ces graphiques rendent facile l’analyse des résultats obtenus et du risque client. La Figure 5.5 montre la répartition des niveaux de risque de churn ainsi que la distribution des probabilités.




FIGURE 5.5 – Visualisations graphiques

5.2.3 Liste des clients à risque

La partie inférieure du tableau de bord affiche la liste des clients prédits comme churn. Les clients sont triés par probabilité décroissante.

Pour chaque client, l’interface affiche le code contrat, le score de churn, le niveau de risque et l’ancienneté. Une barre visuelle facilite la lecture du score. La liste détaillée des clients à risque apparaît dans laFigure 5.6.

Clients identifiés comme churns				
Triés par probabilité décroissante				
Exporter Churners (Excel/CSV)				
#	CODE CONTRAT	PROBABILITÉ CHURN	NIVEAU DE RISQUE	ANCIENNETÉ (MOIS)
1	SN_66806478	99,1%	Élevé	5
2	SN_67091314	99,1%	Élevé	4
3	SN_66880327	99,1%	Élevé	5
4	SN_66979780	99,1%	Élevé	5
5	SN_66805196	99,1%	Élevé	5
6	SN_66944741	99,1%	Élevé	5
7	SN_67031818	99,0%	Élevé	4

FIGURE 5.6 – Liste détaillée des clients à risque

5.3 Exportation des résultats

La page de tableau de bord intègre une fonctionnalité de téléchargement des clients à risque au format CSV, exporté avec les mêmes colonnes affichées dans la liste. La Figure 5.7. illustre cette fonctionnalité.

	A	B	C	D	E	F	G
1	#;CODE_CONTRAT;Probabilite_Churn_%;Niveau_Risque;Anciennete_Mois						
2	1;SN_66806478;99.1;Élevé;5						
3	2;SN_67091314;99.1;Élevé;4						
4	3;SN_66880327;99.1;Élevé;5						
5	4;SN_66979780;99.1;Élevé;5						
6	5;SN_66805196;99.1;Élevé;5						
7	6;SN_66944741;99.1;Élevé;5						
8	7;SN_67031818;99.0;Élevé;4						
9	8;SN_66860938;99.0;Élevé;5						
10	9;SN_67033734;99.0;Élevé;4						
11	10;SN_67032589;99.0;Élevé;4						
12	11;SN_67030117;99.0;Élevé;4						
13	12;SN_67029887;99.0;Élevé;4						
14	13;SN_67024220;99.0;Élevé;4						
15	14;SN_67023419;99.0;Élevé;4						
16	15;SN_67019514;99.0;Élevé;4						
17	16;SN_67016033;99.0;Élevé;4						
18	17;SN_67000183;99.0;Élevé;4						
19	18;SN_67033976;99.0;Élevé;4						
20	19;SN_67035711;99.0;Élevé;4						
21	20;SN_67038878;99.0;Élevé;4						
22	21;SN_67159400;99.0;Élevé;4						
23	22;SN_67177310;99.0;Élevé;4						
24	23;SN_67187229;99.0;Élevé;4						
25	24;SN_67180080;99.0;Élevé;4						
26	25;SN_67206808;99.0;Élevé;4						

FIGURE 5.7 – Export CSV des clients à risque

Conclusion

Ce chapitre a présenté l'intégration du modèle dans une application web. L'interface permet d'importer les données mensuelles, de lancer le modèle XGBoost, de consulter les indicateurs et d'exporter les clients à risque. Les résultats deviennent ainsi plus faciles à utiliser par l'équipe d'exploration de données de Tunisie Telecom.

Conclusion générale

Ce projet avait pour objectif de prédire le churn des clients de Tunisie Telecom à partir de données comportementales et transactionnelles. Dans un secteur fortement concurrentiel, l'identification des clients susceptibles de quitter l'opérateur représente un enjeu important, car elle permet à l'entreprise d'agir de manière proactive et de préparer des actions de fidélisation ciblées.

Pour atteindre cet objectif, nous avons suivi la méthodologie CRISP-DM. Après la compréhension du contexte métier et de la problématique, nous avons exploré les six fichiers fournis : données client, appels sortants, appels entrants, consommation Internet, recharges et services USSD. La phase de préparation des données a été essentielle. Elle a permis de traiter les valeurs manquantes, de corriger certaines incohérences, d'encoder les variables qualitatives et de construire de nouvelles variables décrivant le comportement des clients .

Après la construction du dataset final, plusieurs algorithmes de classification ont été entraînés et comparés. L'évaluation a été réalisée à l'aide de métriques adaptées afin de mesurer la capacité des modèles à identifier les clients à risque. Parmi les modèles testés, XGBoost a donné les meilleurs résultats et a été retenu comme modèle final. Son test sur de nouvelles données réelles a confirmé son intérêt pour l'aide à la décision.

Le projet ne s'est pas limité à la partie modélisation. Une application web a également été développée afin de rendre le modèle exploitable par les utilisateurs. Cette application permet d'importer les fichiers mensuels, de lancer la prédiction, de visualiser les indicateurs clés, de consulter la liste des clients à risque et d'exporter les résultats au format CSV. Elle transforme le modèle en un outil pratique pouvant aider les équipes concernées à mieux cibler leurs actions.

Ce travail nous a permis d'appliquer nos connaissances en exploration de données, en préparation des données, en apprentissage automatique et en développement web. Il a aussi montré que la qualité des données et le choix des variables jouent un rôle essentiel dans la performance d'un modèle prédictif.

Comme perspectives, plusieurs améliorations peuvent être envisagées. Le modèle pourrait être enrichi par l'ajout de nouvelles variables liées au comportement des clients, puis réentraîné régulièrement afin d'améliorer la qualité des prédictions et de maintenir de bonnes performances dans le temps. Du côté applicatif, dès qu'un client est détecté à risque de churn, l'application pourrait envoyer automatiquement une offre de rétention directement depuis l'interface, ce qui faciliterait l'intervention et réduirait le taux de churn.

Références bibliographiques

- [1] Logo Tunisie Telecom. Disponible sur : <https://worldvectorlogo.com/logo/tunisie-telecom>. Consulté le 10 mars 2026.
- [2] Méthodologie CRISP-DM. Disponible sur : <https://www.sv-europe.com/crisp-dm-methodology/>. Consulté le 15 mars 2026.
- [3] Méthodologie SEMMA. Disponible sur : <https://medium.com/@rmramasamy1312/the-effectiveness-of-crisp-dm-semma-and-kdd-comparing-data-mining-methodologies-e4ddbf561c71>. Consulté le 18 mars 2026.
- [4] Processus KDD. Disponible sur : <https://medium.com/@shawn.chumbar/kdd-process-in-data-science-a-beginners-guide-426d1f0fc062>. Consulté le 16 mars 2026.
- [5] Logo Python. Disponible sur : <https://www.python.org/community/logos/>. Consulté le 08 avril 2026.
- [6] Jupyter Notebook. Disponible sur : <https://jupyter.org>. Consulté le 08 avril 2026.
- [7] Anaconda. Disponible sur : <https://www.anaconda.com/>. Consulté le 09 avril 2026.
- [8] Flask. Disponible sur : <https://flask.palletsprojects.com/en/stable/>. Consulté le 10 mai 2026.
- [9] Visual Studio Code. Disponible sur : <https://visualstudio.microsoft.com/>. Consulté le 09 avril 2026.
- [10] Logo StarUML. Disponible sur : https://fr.wikipedia.org/wiki/Fichier:Staruml_logo.png. Consulté le 18 mai 2026.
- [11] Définition de XGBoost. Disponible sur : <https://xgboost.ai/about>. Consulté le 28 avril 2026.
- [12] Définition de l'apprentissage automatique. Disponible sur : <https://www.ibm.com/topics/machine-learning>. Consulté le 05 avril 2026.
- [13] Définition de l'exploration de données. Disponible sur : <https://www.ibm.com/topics/data-mining>. Consulté le 05 avril 2026.
- [14] Matrice de confusion. Disponible sur : https://fr.wikipedia.org/wiki/Matrice_de_confusion. Consulté le 6 avril 2026.